

판별자 유효성 · 일반화 분석 — v4

2026-07-27 · RESULTS_BD_V4_K0.pdf 의 자매 문서. 검증 질문: unseen(e99) 판별자는 새 시나리오로 정말 일반화되는가, 아니면 downstream의 seen~unseen 동등성이 무언가를 가리고 있는가? 본문 disc는 모두 v4 라운드(_v4 , EOS 수정 백본의 pool로 학습)이며, 수정 전(v2) 수치는 교란 사례 연구(\$4)에만 등장한다.

1. 판별자의 역할과 분할 위생

- 역할: guidance에는 블록 조건부 비율 $w = q_{\text{except}}(x_0|x^{<b})/p_\theta(x_0|x^{<b})$ 가 필요하고, disc D는 clean 부분경로 [prefix || block]에서 $D/(1-D)$ 로 이를 추정한다. 시나리오 인접행렬 A_{scn} 이 입력으로 들어간다(GraphSAGE 임베딩 + 위치별 edge-existence 피쳐), logit은 $\ell = 4 \cdot \tanh(z/4)$ 로 유계.
- Seen (e0): positive = except_0 경로 중 평가 예약 1,000행을 제외한 나머지의 1% (RandomState(777) 순열, 앞 1,000행 예약). Unseen (e99): positive = except 1-99만(시나리오 별 1%), except_0는 어떤 gradient에도 기여하지 않음. 학습 중 출력되는 except_0 val acc는 모니터링용 진단일 뿐(고정 4,000 스텝, 모델 선택 없음).
- 아래 모든 평가는 두 disc 모두에게 held-out: except_0 probe는 예약 행, except_1 probe는 e99의 1% 학습 슬라이스 밖 행을 쓰고, negative는 신선하다(학습용 seed-1 pool과 분리된 seed-99 pool; data-negative probe는 신선한 normal 표본).

2. 대칭 probe 설계

두 probe 시나리오가 역할을 뒤집는다: except_0에서는 e0가 in-scenario·e99가 zero-shot, except_1에서는 e99가 in-scenario(held-out 행)·e0가 zero-shot. 일반화가 진짜라면 in-scenario 위는 작아야 하고 probe 방향에 따라 뒤집혀야 한다 — 실제로 정확히 그렇게 나타난다. 지표: AUC, accuracy@0, 동일 입력에 대한 두 disc의 logit Pearson 상관.

3. Model-negative disc (블록별): positive = 실제 except 경로, negative = 신선한 unconditional 생성

3.1 fam 0.05

blk	AUC, except_0 (e0 in-scn)		AUC, except_1 (e99 in-scn)		logit Pearson	
	e0	e99	e0	e99	exc0	exc1
1	0.870	0.833	0.787	0.848	0.904	0.810
2	0.890	0.872	0.843	0.887	0.913	0.837
4	0.897	0.888	0.850	0.901	0.925	0.825
8	0.943	0.931	0.898	0.932	0.956	0.866
16	0.951	0.948	0.930	0.948	0.970	0.947
32	0.956	0.951	0.945	0.952	0.963	0.950
64	0.957	0.958	0.946	0.957	0.976	0.968

3.2 fam 0.1

blk	AUC, except_0 (e0 in-scn)		AUC, except_1 (e99 in-scn)		logit Pearson	
	e0	e99	e0	e99	exc0	exc1
1	0.947	0.935	0.902	0.926	0.950	0.877
2	0.959	0.953	0.914	0.940	0.963	0.920
4	0.962	0.948	0.929	0.946	0.970	0.933
8	0.977	0.971	0.946	0.965	0.975	0.929
16	0.981	0.978	0.962	0.972	0.980	0.959
32	0.977	0.973	0.964	0.971	0.981	0.965
64	0.983	0.977	0.967	0.974	0.980	0.973

- In-scenario 우위가 probe 방향에 따라 뒤집히며 크기가 작다(AUC 0.005-0.06): 어느 쪽이든 zero-shot 입장이 약간 손해를 보는 패턴이 양방향-양 family에서 재현 — 암기가 아닌 진짜 전이의 signature.
- 이 과제에서 전이가 저렴한 것은 구조적: 판별 신호의 대부분 — 입력 인접행렬 대비 edge 합법성, 모델 생성 artifact — 이 시나리오-무관이다. disc가 A_{scn} 을 입력으로 읽으므로 “주어진 인접행렬에 없는 edge ⇒ 가짜” 규칙은 어느 시나리오에나 적용된다.
- 블록 간 AUC 수준은 disc가 아니라 백본을 반영: negative pool의 invalid-edge 비율(v4: blk1 2.3% → blk64 11.4%)과 함께 오른다. 블록 간 AUC 비교는 p_θ 품질(negative 난이도)에 대한 진술이다 — \$4 참조.
- fam 0.1의 AUC가 일괄 높은 것은 제거 edge가 2배라 시나리오 신호가 강하기 때문.

4. Negative pool 교란 — v2 blk1 사례 연구

수정 전(v2) 백본에서는 blk1 disc가 *최고* AUC(0.985), blk2가 *최저*(0.881)로 비단조적이었다. 원인은 disc가 아니라 negative pool: v2 blk1의 unconditional 생성은 퇴화 상태였고(전량 캔버스 캡 도달, 길이 101 vs 실제 23.2; invalid edge 50.5%), 그 negative는 *길이 지름길*만으로 구분 가능했다. EOS 수정 후 blk1 pool이 정상화되자(길이 25.2; invalid 2.3%) blk1 AUC는 정직한 0.870으로 내려왔고, 이제 AUC 순서는 전 블록에서 pool의 invalid-edge 비율에 단조적이다. 교훈: model-negative 학습에서는 **블록별 AUC가 disc 품질과 생성 품질을 뒤섞는다**; 교란 없는 비교는 같은 pool을 공유하는 블록 내 seen-vs-unseen뿐이다.

	pool 길이 (실제 23.2)	pool invE	cap%	AUC e0, exc0
v2 blk1 (수정 전)	101.0±0.0	50.5%	100%	0.985 (<i>길이 지름길</i>)
v4 blk1 (수정 후)	25.2±12.5	2.3%	0.9%	0.870 (<i>정직</i>)

5. Data-negative disc (블록 무관): 엄격한 일반화 probe

positive = 실제 except 경로, negative = 실제 normal 경로 — real vs real이므로 시나리오-무관 지름길(모델 artifact, 길이)이 전부 제거되고 **시나리오 고유 정보**(어떤 edge가 제거됐고 경로가 어떻게 우회하는가)만 두 클래스를 가른다. 방식당 disc 1개, 블록별 pool이 없어 §4 교란도 없다. 이 disc들은 백본과 무관하므로 v2/v4에서 동일하다(같은 시드).

family	AUC, except_0 (e0 in-scen)		AUC, except_1 (e99 in-scen)		zero-shot 하락		Pearson exc0 / exc1
	e0	e99	e0	e99	e0	e99	
0.05	0.845	0.813	0.745	0.835	−0.100	−0.022	0.913 / 0.737
0.1	0.951	0.932	0.867	0.914	−0.084	+0.018	0.956 / 0.834

- 이 probe가 두 학습 방식을 가른다: 단일 시나리오 e0는 zero-shot에서 크게 하락(−0.100/−0.084), 99-시나리오 e99는 거의 평탄(−0.022/+0.018). 시나리오 고유 정보의 일반화는 다중 시나리오 학습의 산물이며, 시나리오 하나는 인접행렬 조건화 규칙이 충분히 학습되지 않는다.
- zero-shot 측에서 logit 상관도 하락(exc1: 0.737/0.834) — 과제가 시나리오-고유해지면 두 disc는 실제로 다른 함수다.

6. 그럼에도 downstream에서 seen ≈ unseen인 이유

- Guidance가 배치하는 것은 model-negative disc이고, 그 신호는 §3처럼 거의 무료로 전이된다 — §5의 어려운 probe는 파이프라인이 배치하지 않는 변형(v3 보고서 §4.1b의 ablation)에 관한 것.
- Self-normalized IS가 calibration을 소개: 가중치 $w_n = \exp(v\ell_n)$ 은 $w_n/\Sigma w_m$ 형태로만 쓰이므로, zero-shot 전이의 주된 손상인 상수 logit 오프셋(accuracy@0가 AUC보다 훨씬 크게 하락)은 정확히 약분된다. 남은 것은 순위/상대차뿐이고, 그것은 전이된다(AUC 격차 ≤0.05).
- Guidance 시점의 채점 대상은 모델 후보들, 즉 model-negative disc가 학습한 바로 그 분포다 — 배치된 disc가 용도에 정합.

7. 결론

Downstream에서 관측된 seen/unseen 동등성($v \wedge a$ 격차: fam 0.05 ≤0.015, fam 0.1 ≤0.003, 전 블록)은 완전히 설명된다: (1) 배치된 model-negative 판별자는 판별 신호가 구조적으로 시나리오-무관이고 인접행렬이 입력이므로 전이되며, (2) SNIS guidance는 zero-shot 전이가 실제로 유발하는 calibration 이동에 불변이고, (3) 독립적으로, 엄격한 real-vs-real probe는 e99 학습 방식이 단일 시나리오 학습은 얻지 못하는 전이 가능한 시나리오-고유 지식을 획득함을 보인다. disc 지표 해석의 유일한 주의점 — 블록별 AUC는 negative pool 난이도를 반영 — 은 v2~v4 blk1 사례로 실증·해소되었다.

출처: `disc_gen_eval.py` : JSON `sets_res/disc_gen_eval_f{005,01}{, _data}_v4.json` : 수정 전 대조 `disc_gen_eval_f005.json` (v2 라운드); pool 통계 `uncond_pool_eval{, _v4}.json` .