

판별자 유효성 · 일반화 분석 — v4

2026-07-27 · RESULTS_BD_V4_K0.pdf 의 자매 문서. 검증 질문: unseen(e99) 판별자는 새 시나리오로 정말 일반화되는가, 아니면 downstream의 seen~unseen 동등성이 무언가를 가리고 있는가? 본문 disc는 모두 v4 라운드(_v4 , EOS 수정 버전의 pool로 학습)이며, 수정 전(v2) 수치는 교란 사례 연구(\$4)에만 등장한다. 본문 지표는 분류 정확도이고, 동일 실험의 AUC는 부록 A에 둔다.

1. 판별자의 역할과 분할 위생

- 역할: guidance에는 블록 조건부 비율 $w = q_{\text{except}}(x_0|x^{<b})/p_\theta(x_0|x^{<b})$ 가 필요하고, disc D는 clean 부분경로 [prefix || block]에서 $D/(1-D)$ 로 이를 추정한다. 시나리오 인접행렬 A_{scn} 이 입력으로 들어간다(GraphSAGE 임베딩 + 위치별 edge-existence 피쳐), logit은 $\ell = 4 \cdot \tanh(z/4)$ 로 유계.
- Seen (e0): positive = except_0 경로 중 평가 예약 1,000행을 제외한 나머지의 1% = 19,308경로 (RandomState(777) 순열). Unseen (e99): positive = except 1-99만(시나리오별 $1\% \times 99 = 1,911,492$ 경로), except_0는 어떤 gradient에도 기여하지 않음. 학습 중 출력되는 except_0 val acc는 모니터링용 진단일 뿐(고정 4,000 스텝, 모델 선택 없음).
- 아래 모든 평가는 두 disc 모두에게 held-out: except_0 probe는 예약 행, except_1 probe는 e99의 1% 학습 슬라이스 밖 행을 쓰고, negative는 신선하다(학습용 seed-1 pool과 분리된 seed-99 pool; data-negative probe는 신선한 normal 표본).

2. 대칭 probe 설계와 지표

두 probe 시나리오가 역할을 뒤집는다: except_0에서는 e0가 in-scenario·e99가 zero-shot, except_1에서는 e99가 in-scenario(held-out 행)·e0가 zero-shot. 일반화가 진짜라면 in-scenario 우위는 작아야 하고 probe 방향에 따라 뒤집혀야 한다.

- 정확도 = positive 1,000 + negative 1,000의 균형 집합에서 $\text{logit} > 0$ (즉 $D > 0.5$, BCE의 자연 임계값 — 튜닝하지 않음)으로 판정했을 때의 적중률. chance = 0.500.
- zero-shot 하락 = (자기 시나리오가 아닌 probe의 정확도) – (자기 시나리오 probe의 정확도). e0는 $\text{exc0} - \text{exc0}$, e99는 $\text{exc0} - \text{exc1}$. 음수가 클수록 시나리오를 옮겼을 때 손해가 크다는 뜻.
- logit Pearson = 동일 입력 2,000개에 대한 두 disc logit의 상관 — 같은 함수를 학습했는지의 직접 증거.

3. Model-negative disc (블록별): positive = 실제 except 경로, negative = 신선한 unconditional 생성

3.1 fam 0.05

blk	정확도, except_0 probe (e0 in-sc)		정확도, except_1 probe (e99 in-sc)		zero-shot 하락		logit Pearson exc0 / exc1
	e0	e99	e0	e99	e0	e99	
1	0.760	0.741	0.677	0.750	-0.083	-0.010	0.904 / 0.810
2	0.772	0.775	0.724	0.795	-0.048	-0.020	0.913 / 0.837
4	0.802	0.809	0.752	0.811	-0.050	-0.002	0.925 / 0.825
8	0.857	0.858	0.794	0.848	-0.063	+0.010	0.956 / 0.866
16	0.875	0.875	0.859	0.873	-0.016	+0.002	0.970 / 0.947
32	0.879	0.880	0.858	0.872	-0.022	+0.008	0.963 / 0.950
64	0.889	0.900	0.871	0.890	-0.018	+0.010	0.976 / 0.968

3.2 fam 0.1

blk	정확도, except_0 probe (e0 in-sc)		정확도, except_1 probe (e99 in-sc)		zero-shot 하락		logit Pearson exc0 / exc1
	e0	e99	e0	e99	e0	e99	
1	0.846	0.838	0.795	0.838	-0.050	0.000	0.950 / 0.877
2	0.869	0.854	0.819	0.844	-0.050	+0.010	0.963 / 0.920
4	0.882	0.863	0.833	0.863	-0.049	0.000	0.970 / 0.933
8	0.911	0.902	0.855	0.887	-0.056	+0.015	0.975 / 0.929
16	0.918	0.908	0.885	0.904	-0.033	+0.004	0.980 / 0.959
32	0.912	0.908	0.899	0.903	-0.013	+0.005	0.981 / 0.965
64	0.934	0.926	0.905	0.916	-0.029	+0.010	0.980 / 0.973

- e99는 시나리오를 옮겨도 사실상 손해가 없다: zero-shot 하락이 fam 0.05에서 -0.020~+0.010, fam 0.1에서 0.000~+0.015. 반면 단일 시나리오 e0는 일관되게 손해(fam 0.05 -0.016~-0.083, fam 0.1 -0.013~-0.056)를 본다. 즉 자기 시나리오에서의 우위는 e0에게만 있고 그마저 작다(exc0에서 e0-e99 = -0.011~+0.019).
- 전이가 저렴한 것은 구조적: 판별 신호의 대부분 — 일력 인접행렬 대비 edge 합법성, 모델 생성 artifact — 이 시나리오-무관이다. disc가 A_{scn} 을 입력으로 읽으므로 "주어진 인접행렬에 없는 edge ⇒ 가짜" 규칙은 어느 시나리오에나 적용된다.

- 블록 간 정확도 수준은 disc가 아니라 백본을 반영: negative pool의 invalid-edge 비율(v4: blk1 2.3% → blk64 11.4%)과 함께 오른다. 블록 간 비교는 p_0 품질(negative 난이도)에 대한 진술이 다 — §4 참조.
- fam 0.1이 일괄 높은 것은 제거 edge가 2배라 시나리오 신호가 강하기 때문.

4. Negative pool 교란 — v2 blk1 사례 연구

수정 전(v2) 백본에서는 blk1 disc가 *최고* 정확도(0.943)이고 blk2가 *최저*(0.766)인 비단조 패턴이었다. 원인은 disc가 아니라 negative pool: v2 blk1의 unconditional 생성은 퇴화 상태였고(전량 캔버스 캡 도달, 길이 101 vs 실제 23.2; invalid edge 50.5%), 그 negative는 **길이 지름길**만으로 구분 가능했다. EOS 수정 후 blk1 pool이 정상화되자(길이 25.2; invalid 2.3%) blk1 정확도는 정직한 0.760으로 내려왔고, 이제 정확도 순서는 전 블록에서 pool의 invalid-edge 비율에 단조적이다. 교훈: model-negative 학습에서는 **블록별 정확도가 disc 품질과 생성 품질을 뒤섞는다**; 교란 없는 비교는 같은 pool을 공유하는 블록 내 seen-vs-unseen뿐이다.

	pool 길이 (실제 23.2)	pool invE	cap%	정확도 e0, exc0
v2 blk1 (수정 전)	101.0±0.0	50.5%	100%	0.943 (<i>길이 지름길</i>)
v4 blk1 (수정 후)	25.2±12.5	2.3%	0.9%	0.760 (<i>정직</i>)

5. Data-negative disc (블록 무관): 엄격한 일반화 probe

positive = 실제 except 경로, negative = **실제 normal** 경로 — real vs real이므로 시나리오-무관 지름길(모델 artifact, 길이)이 전부 제거되고 **시나리오 고유 정보**(어떤 edge가 제거됐고 경로가 어떻게 우회하는가)만 두 클래스를 가른다. 방식당 disc 1개, 블록별 pool이 없어 §4 교란도 없다. 이 disc들은 백본과 무관하므로 v2/v4에서 동일하다(같은 시드).

family	정확도, except_0 probe (e0 in-scn)		정확도, except_1 probe (e99 in-scn)		zero-shot 하락		logit Pearson exc0 / exc1
	e0	e99	e0	e99	e0	e99	
0.05	0.726	0.712	0.641	0.735	−0.085	−0.023	0.913 / 0.737
0.1	0.850	0.837	0.751	0.810	−0.099	+0.026	0.956 / 0.834

- 이 probe가 두 학습 방식을 가른다: 단일 시나리오 e0는 zero-shot에서 정확도 −0.085/−0.099로 떨어지고, 99-시나리오 e99는 −0.023/+0.026로 평탄하다. 시나리오 고유 정보의 일반화는 다중 시나리오 학습의 산물이며, 시나리오 하나는 인접행렬 조건화 규칙이 충분히 학습되지 않는다.
- 과제가 어려워진 만큼 절대 수준도 낮다(fam 0.05 e0 zero-shot 0.641, chance 0.500 대비 +0.14): 실제 경로 두 개를 놓고 "어느 시나리오에서 나왔는가"를 맞추는 것은 원래 어려운 문제다.
- zero-shot 측에서 logit 상관도 하락(exc1: 0.737/0.834) — 과제가 시나리오-고유해지면 두 disc는 실제로 다른 함수다.

6. 그럼에도 downstream에서 seen ≈ unseen인 이유

- Guidance가 배치하는 것은 model-negative disc이고, 그 신호는 §3처럼 거의 무료로 전이된다 — §5의 어려운 probe는 파이프라인이 배치하지 않는 변형(v3 보고서 §4.1b의 ablation)에 관한 것.
- Self-normalized IS가 calibration을 소거: 가중치 $w_n = \exp(y \ell_n)$ 은 $w_n / \sum w_m$ 형태로만 쓰이므로 상수 logit 오프셋은 정확히 약분된다. 실제로 남은 손상은 순위 손상뿐이고, 그것은 작다(배치되는 e99 disc의 zero-shot 정확도 하락 ≤0.020, AUC 하락 ≤0.015 — 부록 A).
- Guidance 시점의 채점 대상은 모델 후보들, 즉 model-negative disc가 학습한 바로 그 분포다 — 배치된 disc가 용도에 정합.

7. 결론

Downstream에서 관측된 seen/unseen 동등성($v \wedge a$ 격차: fam 0.05 ≤0.015, fam 0.1 ≤0.003, 전 블록)은 완전히 설명된다: (1) 배치된 model-negative 판별자는 판별 신호가 구조적으로 시나리오-무관이고 인접행렬이 입력이므로 전이되며(e99의 zero-shot 정확도 하락 ≤0.020), (2) SNIS guidance는 zero-shot 전이가 유발하는 calibration 이동에 불변이고, (3) 독립적으로 엄격한 real-vs-real probe는 e99 학습 방식이 단일 시나리오 학습은 얻지 못하는 전이 가능한 시나리오-고유 지식을 획득함을 보인다(−0.023 vs −0.085). disc 지표 해석의 유일한 주의점 — 블록별 수치는 negative pool 난이도를 반영 — 은 v2→v4 blk1 사례로 실증·해소되었다.

부록 A. 동일 실험의 AUC

정확도는 임계값 0(D = 0.5)에 고정된 지표라 상수 logit 오프셋에 민감하다. SNIS guidance는 그 오프셋에 불변이므로(§6) 이론적으로는 순위 지표인 AUC가 더 정합하고, 정확도는 읽기 쉬운 요약이다. 두 지표는 같은 결론을 준다.

A.1 Model-negative, fam 0.05

blk	AUC, except_0 probe (e0 in-scn)		AUC, except_1 probe (e99 in-scn)		zero-shot 하락		logit Pearson exc0 / exc1
	e0	e99	e0	e99	e0	e99	
1	0.870	0.833	0.787	0.848	−0.083	−0.015	0.904 / 0.810
2	0.890	0.872	0.843	0.887	−0.046	−0.015	0.913 / 0.837
4	0.897	0.888	0.850	0.901	−0.047	−0.013	0.925 / 0.825

8	0.943	0.931	0.898	0.932	-0.045	-0.002	0.956 / 0.866
16	0.951	0.948	0.930	0.948	-0.021	0.000	0.970 / 0.947
32	0.956	0.951	0.945	0.952	-0.011	-0.001	0.963 / 0.950
64	0.957	0.958	0.946	0.957	-0.012	+0.001	0.976 / 0.968

A.2 Model-negative, fam 0.1

blk	AUC, except_0 probe (e0 in-scn)		AUC, except_1 probe (e99 in-scn)		zero-shot 하락		logit Pearson exc0 / exc1
	e0	e99	e0	e99	e0	e99	
1	0.947	0.935	0.902	0.926	-0.045	+0.010	0.950 / 0.877
2	0.959	0.953	0.914	0.940	-0.045	+0.013	0.963 / 0.920
4	0.962	0.948	0.929	0.946	-0.032	+0.001	0.970 / 0.933
8	0.977	0.971	0.946	0.965	-0.031	+0.006	0.975 / 0.929
16	0.981	0.978	0.962	0.972	-0.019	+0.006	0.980 / 0.959
32	0.977	0.973	0.964	0.971	-0.013	+0.002	0.981 / 0.965
64	0.983	0.977	0.967	0.974	-0.017	+0.004	0.980 / 0.973

A.3 Data-negative

family	AUC, except_0 probe (e0 in-scn)		AUC, except_1 probe (e99 in-scn)		zero-shot 하락		logit Pearson exc0 / exc1
	e0	e99	e0	e99	e0	e99	
0.05	0.845	0.813	0.745	0.835	-0.100	-0.021	0.913 / 0.737
0.1	0.951	0.932	0.867	0.914	-0.084	+0.019	0.956 / 0.834

출처: `disc_gen_eval.py` ; JSON `sets_res/disc_gen_eval_f{005,01}{, _data}_v4.json` ; 수정 전 대조 `disc_gen_eval_f005.json` (v2 라운드); pool 통계 `uncond_pool_eval{, _v4}.json` .