

LE vs LP — choice set 생성 방식이 가이드런스 효과를 바꾸는가

1. 가설

v6 의 두 데이터셋은 예외 시나리오가 다른 것이 아니라 **choice set** 생성 방식이 다르다. OD 쌍마다 choice set 을 먼저 만들고 그 중 하나를 참조 경로로 뽑는데, 만드는 방법이 이렇게 갈린다.

데이터셋	choice set 생성	구성원의 성질
LE (link elimination)	edge 를 삭제하며 최단경로를 반복 수집	모든 구성원이 어떤 부분그래프에서의 최단경로
LP (link penalization)	edge 비용에 벌점을 주며 최단경로를 반복 수집. edge 는 삭제되지 않는다	수정된 비용 아래의 최단경로 — 홑 수로는 어느 부분그래프에서도 최단이 아니다

한편 **except_e** 시나리오는 **edge** 를 삭제한다. 그러면 LE 쪽에는 구조적 혼입이 생긴다 — **LE** 의 학습 분포에는 이미 “**edge** 가 빠진 그래프의 최단경로”가 가득하다. 시나리오가 edge 를 지워 만든 경로가 LE 의 평범한 데이터와 구별이 잘 안 된다는 뜻이고, 판별자의 **positive** 클래스가 그만큼 덜 특징적이 된다. LP 에는 삭제를 닮은 것이 학습 분포에 없으므로 시나리오 신호가 더 깨끗해야 하고, **따라서 가이드نس가 LP 에서 더 잘 들어야 한다**. 이것이 검증 대상이다.

간접적인 논거임을 분명히 해 둔다 — LE 의 choice set 삭제와 시나리오 삭제는 같은 연산이지만 같은 edge 집합이 아니다. 그래서 예측을 세 갈래로 쪼개 각각 측정했다.

2. 전제 확인 — 시나리오 교란은 두 데이터셋에서 동일하다

먼저 확인해야 할 것은 “LE 와 LP 가 시나리오 자체에서 다르지 않다”는 점이다. 다르면 이후 비교가 전부 오염된다. **except_e** 그래프를 normal 과 비교했다 (10 개 시나리오 평균).

항목	LE	LP	차	가설 예상	비고
normal edge 수	3996	3996	0	✓	
시나리오 edge 수	3798.0	3798.1	-0.1	✓	
삭제된 edge	198.0	197.9	0.1	✓	
추가된 edge	0.0	0.0	0.0	✓	
삭제 비율	0.0495	0.0495	0.0000	✓	
except_0 ∩ except_1 삭제 겹침	12	8	4		198개 중. 시나리오는 서로 독립에 가깝다

동일하다. 둘 다 3996 개 중 **198 개(4.95%)**를 삭제하고 추가는 0 이다. 그러므로 “LE 는 edge 를 지우는 데이터”라는 말은 **시나리오**에 대해서는 LP 에도 똑같이 적용된다. 가설이 성립할 자리는 시나리오가 아니라 **choice set** **쪽뿐**이며, 이 표는 그 점을 확정한다.

부수 확인 — 참조 경로가 자기 시나리오 그래프에서 합법인가? LE 0/1000, LP 0/1000 가 불법이고 불법 edge 는 0/27310 와 0/28043 다. 즉 둘 다 0. “LP 는 벌점만 줬으니 참조 경로가 벌점 링크를 계속 쓴다”는 가능성은 배제된다 — 벌점은 choice set 을 만들 때만 쓰이고, 뽑힌 경로는 시나리오 그래프에서 온전히 합법이다.

3. 예측 1 (확인됨) — LE 참조 경로가 최단경로에 더 가깝다

가설의 가장 직접적인 결과다. LE 구성원이 **부분그래프의 최단경로**라면, 뽑힌 참조 경로도 최단경로에서 덜 벗어나야 한다. LP 는 벌점을 피해 우회하므로 더 벗어나야 한다. BFS 홑 최소 경로를 기준으로 재면 네 지표가 모두 같은 방향을 가리킨다.

항목	LE	LP	차	가설 예상	비고
참조 경로 길이 (홑)	28.31	29.04	-0.73	✓	BFS 는 두 데이터셋에서 23.94 홑으로 동일(OD 쌍이 같다)
BFS 대비 초과 홑	4.37	5.11	-0.73	✓	
우회 비율 ref / BFS	1.197	1.222	-0.026	✓	
BFS 와의 DTW (m)	4342	5207	-865	✓	기하 이탈. 작을수록 최단경로에 가깝다
BFS 와의 LCS	12.16	11.16	1.00	✓	최단경로와 공유하는 노드 수. 클수록 가깝다
BFS 와 길이가 같은 비율	0.092	0.093	-0.001		이 지표만 차이가 없다 — 아래 주석 참조
BFS 보다 짧은 비율	0.000	0.000	0.000		정의상 0. BFS 가 홑 최소이므로

예측대로다. LE 참조 경로는 평균 4.37 홑만 우회하는데 LP 는 5.11 홑 우회한다. BFS 와의 DTW 도 LE 4342 m 대 LP 5207 m, LCS 도 LE 12.16 대 LP 11.16 로 LE 가 일관되게 더 “최단경로 같다”. **choice set** 생성 방식이 참조 경로의 성격에 실제로 각인된다는 뜻이고, 가설의 전제가 데이터에서 확인된 것이다.

“BFS 와 길이가 같은 비율”만 차이가 없다(9.2% 대 9.3%). 당연하다 — LE 구성원이 최단인 것은 **choice set** 을 만들 때 쓴 부분그래프에서이고, 우리가 비교하는 BFS 는 **except_0** 그래프에서의 최단경로다. 두 부분그래프가 다르므로 정확히 일치할 이유가 없다. 평균적으로 더 가까울 뿐이며, 위의 연속 지표들이 바로 그 “평균적으로”를 잡아낸다.

4. 예측 2 (기각됨) — 판별자 학습 난이도는 차이가 없다

가설이 맞다면 LE 의 판별자 학습이 더 어려워야 한다. positive(except_0 경로)가 negative(무조건 모델 pool)와 덜 구별되기 때문이다. e0 판별자의 학습 로그에서 마지막 스텝의 정확도를 곱어 비교했다.

blk	LE			LP		
	train	val	logit_std	train	val	logit_std
1	0.812	0.723	1.900	0.830	0.703	2.110
2	0.811	0.707	1.930	0.828	0.695	1.870
4	0.839	0.707	2.000	0.857	0.703	1.900
8	0.876	0.727	2.010	0.871	0.695	2.070
16	0.898	0.715	2.110	0.906	0.719	2.250
32	0.896	0.691	2.240	0.900	0.742	2.140
64	0.899	0.719	2.250	0.918	0.719	2.170

차이가 없다. val 정확도 평균이 LE **0.713** (0.691–0.727), LP **0.711** (0.695–0.742) 로 사실상 같고 블록별 대소도 뒤섞인다. logit_std 도 1.87–2.25 로 겹친다. 그러므로 가설이 맞다 해도 그 효과는 **학습 과제의 난이도로는 나타나지 않는다**. 이런 이상한 일이 아니다 — 학습/검증 과제는 “경로 하나를 보고 시나리오 데이터인지 판정”인데, 배포 과제는 “같은 스텝에 같은 pθ 가 낸 후보들의 순위 매기기”로 훨씬 어렵고 다른 능력을 요구한다. 효과가 있다면 후자에서 보일 것이다.

5. 예측 3 (부분 확인) — 가이드نس 기여

배포 과제에서의 판별자 기여를 직접 재려면 **마스킹만 쓴 arm 을 기준으로** 삼아야 한다. Adj+IW - Adj-only 가 곧 재가중이 순수하게 보탠 몫이다(v&a, rawL, seen). n_is 스위프 전체를 함께 실어 n 에 의존하지 않는 값인지도 같이 본다.

blk	LE							LP						
	n=10	n=30	n=50	n=100	n=150	평균	추세	n=10	n=30	n=50	n=100	n=150	평균	추세
1	+0.000	+0.013	+0.004	+0.009	+0.008	+0.007	~	-0.009	-0.008	-0.004	+0.000	+0.001	-0.004	↑
2	+0.022	+0.022	+0.021	+0.020	+0.025	+0.022	~	+0.033	+0.019	+0.025	+0.029	+0.036	+0.028	↗
4	+0.023	+0.024	+0.030	+0.037	+0.045	+0.032	↑	+0.014	+0.022	+0.023	+0.031	+0.031	+0.024	↑
8	+0.036	+0.050	+0.039	+0.039	+0.028	+0.038	~	+0.023	+0.027	+0.021	+0.030	+0.018	+0.024	~
16	+0.022	+0.020	+0.019	+0.015	+0.012	+0.018	↓	-0.009	-0.004	+0.007	+0.004	-0.014	-0.003	~
32	+0.014	+0.008	+0.026	-0.013	+0.033	+0.014	~	+0.035	+0.026	+0.038	+0.026	+0.036	+0.032	~
64	+0.004	+0.004	+0.005	+0.014	+0.007	+0.007	~	+0.024	+0.034	+0.046	+0.045	+0.050	+0.040	↗

혼재한다. 가설이 예측하는 방향(LP > LE)은 7개 블록 중 3개에서만 맞고, 4개에서는 반대다.

- blk1: LE +0.007 / LP -0.004 — 반대 방향 (차 -0.011) — 둘 다 0 에 가깝다, 마스킹만으로 포화
- blk2: LE +0.022 / LP +0.028 — 가설 방향 (차 +0.006) — 성능 운용점
- blk4: LE +0.032 / LP +0.024 — 반대 방향 (차 -0.008)
- blk8: LE +0.038 / LP +0.024 — 반대 방향 (차 -0.015)
- blk16: LE +0.018 / LP -0.003 — 반대 방향 (차 -0.021)
- blk32: LE +0.014 / LP +0.032 — 가설 방향 (차 +0.019)
- blk64: LE +0.007 / LP +0.040 — 가설 방향 (차 +0.033)

즉 블록 크기가 데이터셋보다 큰 변수다. 그리고 그 의존이 무작위가 아니라 **블록 크기에 따라 부호가 뒤집힌다**: 작은·중간 블록에서는 LE 가, 큰 블록에서는 LP 가 앞선다. 가설은 데이터셋 전체에 걸친 우열을 예측했으므로 이 구조는 가설로 설명되지 않는다. 게다가 **운용점은 blk2(v&a 0.79–0.80, 큰 블록은 0.44–0.53)**이고 거기서의 차이는 0.006 로 v&a 표본오차 0.013 수준이다.

후보 다양성(마스킹 ON, 고유 후보 수)을 나란히 두면 blk64 의 차이가 왜 그쪽에서 나는지 보인다 — 후보가 많아지는 구간에서만 재가중이 쓸 재료를 갖는다.

blk	LE					LP				
	n=10	n=30	n=50	n=100	n=150	n=10	n=30	n=50	n=100	n=150
1	1.6	2.0	2.2	2.6	2.9	1.6	2.0	2.2	2.7	2.9
2	1.8	2.4	2.9	3.6	4.2	1.9	2.7	3.2	4.1	4.8
4	1.7	2.4	2.9	3.7	4.4	1.8	2.7	3.2	4.2	5.0

8	2.4	4.5	6.3	11.7	15.8	2.8	5.3	7.3	11.3	14.8
16	3.6	8.3	12.0	24.0	30.2	4.0	8.8	13.6	22.6	30.3
32	4.0	10.0	21.5	28.1	58.9	5.3	10.6	16.4	31.3	44.8
64	5.1	13.3	21.5	40.3	59.8	3.4	8.2	13.0	24.8	35.5

6. 결론

가설은 메커니즘으로는 실패하고, 결과로는 약하다.

- **실패한다:** choice set 생성 방식이 참조 경로에 각인된다는 것이 네 지표에서 일관되게 확인된다. LE 참조 경로는 최단경로에 더 가깝고(초과 흡 4.37 대 5.11), 이는 LE 가 삭제 기반이라는 정의의 직접적 귀결이다.
- **약하다:** 그 각인이 판별자 학습 난이도로는 전혀 나타나지 않고 (val acc 0.713 대 0.711), 가이드نس 기여로도 **블록 크기에 따라 부호가 뒤집힌다**(작은·중간 블록 LE 우세 4개 / 큰 블록 LP 우세 3개). 가설은 데이터셋 전체의 우열을 예측하므로 이 구조를 설명하지 못한다. 운용점 blk2 에서의 차이는 0.006 로 표본오차 안이다.
- **따라서 논문에서 쓸 수 있는 형태는** “LP 에서 가이드نس가 더 잘 듣는다”가 아니라, “**두 choice-set 생성 방식 모두에서 같은 결론이 재현된다**”는 강건성 진술이다. 실제로 blk2 에서 Adj+IW 가 최선인 것, 마스킹이 기여의 대부분을 설명하는 것, 그리고 **운용 블록에서 n_is 가 평평한 것이** LE/LP 양쪽에서 동일하게 나타난다. (단 “n_is 에 평평”은 **전 블록에 걸친 진술이 아니다** — LE blk4 와 LP blk64 에서는 기여가 n 에 따라 단조 증가한다. n_is 스왑 보고서의 해당 절 참조.)

제대로 검증하려면. 지금 비교는 데이터셋 2 개 × 블록 7 개의 관측치라 블록 효과와 데이터셋 효과가 분리되지 않는다. 가설을 정면으로 재려면 LE 의 choice set 삭제 edge 집합과 except_e 삭제 집합의 **겹침을 통제**해야 한다 — 겹침이 큰 OD 쌍과 작은 OD 쌍으로 나눠 가이드نس 기여를 비교하면, 같은 데이터셋 안에서 가설을 직접 검증할 수 있다. 그 정보는 상류 `porto_openstreetmap/path_data/v6` 의 choice set 생성 산출물에 있어야 한다.

출처. 데이터셋 사실 `tools/diag/le_vs_lp_facts.py` → `sets_v6/le_vs_lp_facts.json` · 최단경로 기준선 `tools/eval/shortest_baseline.py` · 가이드نس 기여 `scripts/run_v6_nis.sh` 의 rawL 표 · 후보 다양성 `tools/diag/diag_proposal_diversity.py` · 판별자 정확도는 `sets_v6/{LE,LP}/log/disc_e0_blk*.log` 의 마지막 스텝. 평가는 두 데이터셋 모두 동일한 1,000 OD 쌍(SPLIT_SEED 777), `order=l2r` , `w_gamma=1.0` .