

Block-Diffusion OD Planning — Block Size Sweep (mask 커널, raw)

상태 (2026-07-16). mask 커널의 block size {1, 2, 4, 8, 16, 32, 64} 7종 모두 최종: 새 서버(143.248.84.179, RTX 3090 ×4, GPU당 1런, 2웨이브; 런당 학습 43-54분)에서 학습·평가 완료, tmux 세션 정상 종료. 요청에 따라 이 보고서의 모든 수치는 raw — `eval_shortest.refine()` (`refine_es`)도, 최단경로 패치 (`refine_nx`)도 일절 없음; 따라서 hit = arrival. 이전 보고서(blk4 단독, refine 변형 포함): RESULTS_BD_prev.pdf . 2026-07-17 갱신: §4(실패 해부), §5(후처리 P1/P3), §6(importance-weight guidance — 33런 + adjacency-masked proposal 14런, §6.5; Lemma 3 포함 수식은 BD_GUIDANCE_FORMULATION.pdf) 추가. bd3lms 원본 대비 코드 검증: BD_CODE_VERIFICATION_{KO,EN}.pdf .

설정 — swept block size를 제외하면 RESULTS_BD_prev.pdf 와 동일. BD3-LM 방식 block diffusion (블록 간 semi-AR, 블록 내 absorbing/[MASK] diffusion, SUBS 가중 CE, first-hitting 샘플링). Transformer 디노이저: 6층, dim 256, adaLN conditioning (~6.8M 파라미터). 학습 1 epoch = 48.2k iter (bs 32, lr 5e-4), 데이터 `porto_v3_normal` (index v3-0.05, 정점 1,390, 경로 193만). 캔버스는 프로젝트 길이 스펙 [`dst, ori, v1, ..., v_L=dst, END...END | PAD...PAD`] : dst 블록 내부의 END tail은 학습 대상, 이후 PAD 블록은 loss 제외. 조건화: `dst + ori`를 클린 in-context prefix 토큰으로 + OD 임베딩을 adaLN으로; 조건 dropout 0.1; CFG off (`w = 1`). 생성은 open-ended (`length_mode=open`) : `dst(hit)` 또는 `END(miss)`가 나올 때까지 블록 추가 — 길이 모델 없음.

평가. 런당 held-out OD쌍 1,000개, open-ended, raw만. `hit` = 후처리 없이 dst 도달 (이 보고서에선 = arrival); `valid^hit` = 사용 가능 경로 비율; EM / PC / DTW / 길이 지표는 동반 보고서와 동일. 주의: 런마다 평가 1,000쌍을 독립적으로 추출하므로(로드 시 무시드 셔플) 런 간 ~±1%p는 표집 노이즈 이내.

1. Block size sweep — mask 커널, raw (refine 없음)

block size	hit (=arrival)	valid	valid^hit (raw)	EM	PC	DTW	len err	len corr	gen len	real len	s/path
1	0.997	0.943	0.943	0.845	0.883	0.030	0.69	+0.878	23.5	23.0	0.012
2	0.924	0.809	0.777	0.755	0.778	0.044	0.49	+0.977	23.3	23.2	0.004
4	0.943	0.853	0.821	0.789	0.816	0.035	0.32	+0.995	23.7	23.6	0.004
8	0.953	0.807	0.777	0.729	0.761	0.041	0.35	+0.995	22.9	22.9	0.004
16	0.912	0.633	0.598	0.554	0.584	0.062	0.64	+0.979	23.0	23.0	0.004
32	0.900	0.526	0.488	0.443	0.476	0.063	0.69	+0.992	23.4	23.4	0.005
64	0.877	0.504	0.454	0.400	0.439	0.069	0.88	+0.986	24.1	24.0	0.007

굵게 = 열 최고. s/path: first-hitting은 어느 block size든 생성 토큰당 ~1 forward라 시간이 거의 평평함; blk1의 3배 오버헤드는 블록당 외부 루프(append → denoise → scan을 토큰마다) 때문.

2. 실제 경로 길이 구간별 arrival (raw) — horizon 테스트

block size	len 2-15	len 16-25	len 26-35	len 36+
1	0.992	1.000	0.996	1.000
2	0.844	0.941	0.958	0.958
4	0.864	0.953	0.978	0.970
8	0.926	0.956	0.961	0.982
16	0.865	0.919	0.931	0.943
32	0.876	0.871	0.934	0.957
64	0.873	0.892	0.884	0.833

3. 발견

- 블록이 작을수록 좋고, blk1(AR 극한)이 전면 우승. 블록이 1 → 64로 커질수록 arrival 0.997 → 0.877, validity 0.943 → 0.504. blk1은 refine 없이 이 벤치마크를 사실상 해결 — 99.7%가 스스로 dst 도달, 94.3%가 동시에 edge-valid.
- 큰 블록이 지불하는 것은 validity. hit은 완만히(−12%p) 떨어지지만 validity는 급락(−44%p). 블록 내부에서 first-hitting이 무작위 순서로 토큰을 공개하므로, 큰 블록에서는 이미 확정된 비인접 앵커 사이를 잇는 양방향 제약 채우기가 자주 발생 — edge-validity가 정확히 그 국소 일관성이다. blk1은 좌→우 생성이라 매 스텝이 직전 정점을 조건으로 가짐.
- blk2-8 고원, 이후 절벽. blk2-8은 통계적으로 근접(valid^hit 0.78-0.82, 그중 blk4 최고); blk16부터 모든 일관성 지표가 급락(0.60 → 0.45). 블록 병렬성이 필요 하면 blk4가 sweet spot — 이전 보고서의 선택과 일치.

- **blk4가 이전 보고서를 재현.** hit 0.943 / valid^hit 0.821 vs 이전 0.952 / 0.820 — 다른 서버·평가 추출·데이터 순서에서 ±1%p 표집 노이즈 이내. 파이프라인 전 구간 안정.
- **blk64를 빼면 horizon 붕괴 없음.** 점진적 블록 커밋 덕에 blk1-32에서는 경로가 길어져도 arrival이 유지(또는 상승); blk64만 len 36+에서 감쇠(0.833). full-canvas 트랙의 horizon 복리 실패는 어디서도 재발하지 않음.
- **창발 길이는 모든 block size에서 보정 유지:** gen len이 real len을 평균 0.1-0.5토큰 이내로 추적, blk ≥ 2에서 len corr ≥ +0.977. blk1의 낮은 corr(+0.878)은 hit 율 99.7%로 인한 통계적 아티팩트이지 보정 실패가 아님.
- **AR↔diffusion 트레이드의 해석.** BD3-LM 논문의 핵심 트레이드오프가 계획 도메인에서 재현: block size는 블록 내 병렬성을 사고 우도·일관성을 지불한다. 이 그래프 제약 과제에서 그 비용은 거의 전부 edge validity에 얹힌다. 코드 검증에서의 주의점: 본 구현은 bd3lms의 clipped noise schedule(작은 블록에서 효과가 큰 분산 감소)을 생략 — 즉 작은 블록 수치는 원본 레시피 대비 *과소평가*될 수 있으며, 이는 small-block 결론을 오히려 강화한다. sweep 내부 비교는 전 구간 동일 조건이라 영향 없음.

4. 실패 해부 — 길이 보정의 출처, miss의 정체, validity가 떨어지는 이유

이 절의 측정은 저장된 체크포인트에 새로 400쌍을 추출해 돌린 사후 진단 (refine 없음); n_miss = 21-49라 하위집단 비율에는 ~±10%p 표집 노이즈.

4.1 높은 len corr는 대부분 dst-절단 기하학이지 END 예측이 아니다

생성 길이는 hit 경로에선 **dst 토큰이 방출되는 위치**(경로가 dst에서 절단됨)로, miss 경로(~5-12%)에서만 **END 방출 위치**로 결정된다. 하위집단별 분해:

block size	hit	len corr (전체)	len corr (hit만)	len corr (miss만)	hit 우회율 gen/real
64	0.877	0.985	0.991	0.952	1.011
16	0.927	0.988	0.988	0.970	1.011
4	0.963	0.980	0.990	0.778	1.012

hit 경로는 실제(최단) 경로 대비 ~1.1%만 우회하며 dst에 도달하므로 길이는 OD쌍의 그래프 거리에 고정 — corr 0.99는 기하학의 귀결. 이것이 blk64에서 validity가 무너져도 len corr가 0.99로 유지되는 이유: 큰 블록이 깨는 것은 국소 edge 일관성이지 "dst까지 몇 토큰"의 전역 구조가 아니다. END 보정은 실재하지만 부차적: miss 만 관장하며 거기서도 양호(대형 블록에서 miss-only corr 0.95-0.97, 평균 길이 일치) — END가 없었다면 miss가 캔버스 한계까지 폭주해 전체 corr를 끌어내렸을 것.

4.2 miss는 near-miss다: 모델은 목적지 문 앞까지 간다

miss = dst 정점을 한 번도 밟지 않은 채 END(종료 선언)를 방출한 경우: 본 raw 보고서에선 후처리가 없어 arrival 실패로 집계된다. miss 경로의 마지막 정점에서 dst까지의 그래프 hop 거리:

block size	n_miss	중앙값 hops	평균	≤1 hop	≤2 hops	≤5 hops
64	40	1	1.8	52%	92%	98%
16	39	2	3.3	33%	87%	95%
4	21	1	2.8	52%	81%	90%

hit율과 합치면 **blk64에서도 전체 경로의 ~99%가 dst 2 hop 이내에서 종료**. miss는 내비게이션 실패가 아니라 마지막 순간의 토큰 식별 실패("정확한 dst id 대신 END 방출") — dst 직후 END를 학습시키는 길이 스펙의 예측 가능한 부작용이기도 하다. 이전 보고서에서 refine_es(dst 인접 정점에서 절단 + dst 부착)가 arrival을 +3%p 회복할 수 있었던 이유와 정확히 맞물린다.

4.3 대형 블록에서 validity가 떨어지는 이유: 희소한 국소 스킵의 경로 단위 증폭

	blk64	blk16
invalid edge (edge 단위)	3.6% (332 / 9,130)	2.2% (199 / 9,150)
invalid edge ≥1개 포함 경로	52%	33%
해당 경로당 invalid edge 수	1.6	1.5
invalid 쌍의 실제 hop 거리	중앙값 3; 91% ≤ 3	중앙값 3; 87% ≤ 3
발생 위치	블록 내부 332, 블록 경계 0	내부 188, 경계 11

- **붕괴가 아니라 증폭.** blk64의 edge 단위 정확도는 여전히 96.4%; 경로당 ~23 edge이므로 P(전부 유효) ≈ 0.964²³ ≈ 0.43 — 관측치 0.50과 일치. all-or-nothing 경로 지표가 3.6%의 edge 오류를 50%의 경로 실패로 보이게 한다.
- **오류는 전부 블록 내부.** 블록 경계 edge(이전 블록 완전 커밋 후 생성 = 사실상 AR)는 invalid 0건. 원인은 first-hitting의 블록 내 *무작위* 공개 순서: 비인접 앵커 사이의 양방향 제약 조건부는 좌→우 조건부보다 조합적으로 어렵고 덜 정확하게 학습되며, 블록이 클수록 그런 패턴이 많아진다.
- **스킵은 국소적.** invalid 쌍의 실거리는 2-3 hop(중앙값 3): 다리 정점 하나를 빠뜨리는 것이지 순간이동이 아니다.

4.4 시사점 — 개선 방향

- 대형 블록에서도 모델은 망가지지 않았다: 전역 구조(중점 배치·길이·근최단 경로)는 온전; 결합은 희소(3.6%)·국소(2-3 hop)·정확히 위치 지정 가능(인접성 검사). 이 실패 프로파일은 재학습보다 후처리에 유리하다.
- Local splice (P1, §5에서 구현): invalid (u, v)마다 최단경로 삽입(중앙값 정점 2개). 구조상 validity → 1.0, 중점 불변으로 hit 유지.
- 학습 쪽 수정은 2차적: 용량/epoch/clipped schedule로 edge 오류율은 낮출 수 있으나 any-order infilling은 본질적으로 AR보다 어렵다(원 논문의 블록-우도 경향).
- 샘플러 쪽 수정은 분포를 바꾼다: 블록 내 좌→우 공개나 인접행렬 제약 디코드는 균등 선택 first-hitting과 학습된 역과정의 등가성을 깨는 별도 디코더 — 학습된 모델의 조건부는 순서-일관적이지 않고, 좌→우가 의존하는 prefix 조건부 패턴은 대형 블록의 무작위 마스킹 학습에서 드물다. 경험적 검증 필요.

5. 후처리 결과 — P1 (local splice), P3 (endpoint patch), P1+P3

§4.4의 구현(eval_bd_postproc.py): 체크포인트마다 1,000쌍을 한 번 생성(raw)한 뒤 같은 생성물에 세 후처리를 적용해 채점. P1: invalid (u, v)마다 최단경로 u→v 삽입; P3(= refine_nx): miss 중점에서 dst까지 graft; P1+P3: 둘의 결합. 새로 추출한 평가셋(seed 1)이라 raw 값은 §1과 ±1%p 이내에서 다름.

blk	변형	arrival	valid	valid^hit (raw)	EM	PC	DTW	len err	patch len
1	raw	0.998	0.935	0.935	0.836	0.874	0.036	0.64	—
	P1	0.998	1.000	0.998	0.854	0.902	0.035	0.94	0.42
	P3	1.000	0.935	0.935	0.836	0.874	0.035	0.68	0.04
	P1+P3	1.000	1.000	0.998	0.854	0.902	0.034	0.99	0.46
2	raw	0.937	0.797	0.761	0.735	0.761	0.053	0.62	—
	P1	0.937	0.999	0.937	0.783	0.846	0.052	1.80	1.71
	P3	1.000	0.797	0.761	0.724	0.753	0.051	0.68	0.21
	P1+P3	1.000	1.000	0.937	0.773	0.837	0.050	1.95	1.92
4	raw	0.958	0.822	0.794	0.737	0.773	0.040	0.46	—
	P1	0.958	1.000	0.958	0.772	0.847	0.044	1.19	0.96
	P3	1.000	0.822	0.794	0.729	0.768	0.042	0.59	0.19
	P1+P3	1.000	1.000	0.958	0.764	0.841	0.043	1.33	1.14
8	raw	0.960	0.790	0.768	0.704	0.739	0.040	0.42	—
	P1	0.960	1.000	0.960	0.764	0.845	0.045	1.13	1.05
	P3	1.000	0.790	0.768	0.698	0.735	0.039	0.49	0.15
	P1+P3	1.000	1.000	0.960	0.757	0.838	0.044	1.23	1.20
16	raw	0.885	0.626	0.569	0.541	0.575	0.072	0.63	—
	P1	0.885	1.000	0.885	0.612	0.727	0.076	2.35	2.24
	P3	1.000	0.626	0.569	0.523	0.562	0.068	0.79	0.36
	P1+P3	1.000	1.000	0.885	0.588	0.708	0.072	2.58	2.59
32	raw	0.885	0.522	0.474	0.450	0.478	0.061	0.77	—
	P1	0.885	1.000	0.885	0.582	0.705	0.062	1.96	1.80
	P3	1.000	0.522	0.474	0.432	0.466	0.059	0.85	0.26
	P1+P3	1.000	1.000	0.885	0.558	0.686	0.060	2.14	2.06
64	raw	0.886	0.517	0.465	0.423	0.458	0.055	0.81	—
	P1	0.886	1.000	0.886	0.588	0.711	0.058	1.85	1.75
	P3	1.000	0.517	0.465	0.411	0.450	0.054	0.90	0.27
	P1+P3	1.000	1.000	0.886	0.569	0.695	0.056	2.01	2.01

block size마다 같은 생성물의 네 변형 (파일: sets_res/BD_mask_blk*_postproc.res). 열 정의: hit은 항상 후처리 전 출력에서 측정되므로 valid^hit (raw)는 후처리로 부풀 수 없다 — P1+P3(valid = arrival = 1.0 구조 보장)에서는 남은 유일한 모델 의존량인 raw hit rate와 같다. blk2의 P1 valid 0.999는 연결 경로가 없는 invalid 쌍 1건을 그대로 둔 것.

- §4.4의 예측이 거의 정확히 실현: blk64에서 valid^hit 0.465 → 0.886 (= hit), 평균 패치 비용 1.75토큰; 수선 불가 쌍은 전 런에서 0건.

- P1은 대형 블록에서 EM/PC도 개선 (blk64 EM 0.423 → 0.588, PC 0.458 → 0.711): 삽입된 다리가 실제 경로 조각이라 참조 경로와 겹침 — 패치가 경로를 합법화 할 뿐 아니라 실제 경로 쪽으로 이동시킨다.
- P1+P3는 모든 block size에서 valid = 1 $\wedge$ arrival = 1의 구조적 보장을 제공하며 DTW는 거의 불변, len err는 +0.3-2.0토큰. 이 후처리 하에서 사용 가능 경로 비율 = raw hit rate — 후처리가 대형 블록의 validity 비용을 전부 흡수하고, 남은 block size 페널티는 hit뿐.

6. 예외 상황(except_0)에서의 importance-weight guidance

설계·유도 전문: pdfs/BD_GUIDANCE_FORMULATION.pdf . 부분 경로 discriminator(edge-existence 채널 + 시나리오 인접행렬 GraphSAGE, bounded logit, label smoothing)가 매 first-hitting reveal에서 mean-field 후보 N = 100개를 w = D/(1-D)로 재가중. 백본은 §1의 normal 학습 체크포인트(v4-normal $\equiv$ v3-normal); 평가 = 예약된 except_0 OD쌍 1,000개, 예외 인접행렬 기준 채점, raw. rem-path = 제거된 edge를 1개 이상 쓴 경로 비율; ESS = importance weight의 유효 표본 수 (reveal당 평균; N = 100).

6.1 주축 — block size $\times$ guidance (fam 0.05, 데이터 1%, 실험 1)

blk	변형	arrival	valid (exc)	valid $\wedge$ hit (raw)	rem-path	EM	PC	ESS/100
4	base	0.939	0.253	0.239	0.661	0.231	0.240	—
	guided (data)	0.948	0.306	0.284	0.651	0.269	0.285	99.1
	guided (mix)	0.948	0.315	0.290	0.651	0.281	0.296	99.1
8	base	0.944	0.242	0.229	0.656	0.211	0.223	—
	guided (data)	0.937	0.286	0.268	0.648	0.266	0.275	98.8
	guided (mix)	0.936	0.293	0.271	0.646	0.272	0.281	98.8
16	base	0.896	0.206	0.181	0.642	0.177	0.188	—
	guided (data)	0.885	0.245	0.208	0.625	0.213	0.225	97.9
	guided (mix)	0.884	0.250	0.215	0.630	0.214	0.228	98.0
32	base	0.897	0.165	0.153	0.657	0.136	0.147	—
	guided (data)	0.885	0.199	0.172	0.649	0.156	0.173	97.4
	guided (mix)	0.878	0.205	0.169	0.649	0.165	0.181	97.8
64	base	0.864	0.164	0.151	0.634	0.131	0.145	—
	guided (data)	0.876	0.205	0.181	0.630	0.157	0.176	94.1
	guided (mix)	0.882	0.204	0.183	0.635	0.157	0.175	95.5

6.2 Pivot (blk 4 / 16)

축	구성	blk4 valid (base→guided)	blk16 valid (base→guided)	해석
더 어려운 시나리오	fam 0.1, 1%, 실험 1 (mix)	0.096 → 0.120	0.057 → 0.088	2배 어려운 그래프(rem-path 0.86)에서도 같은 상대 개선
데이터 양	fam 0.05, 3%, 실험 1 (mix)	0.253 → 0.311	0.206 → 0.253	1%와 사실상 동일 — 데이터 양은 병목이 아님
unseen 시나리오 (실험 2)	disc는 except 1-99로 학습, 평가는 except_0 (data)	0.253 → 0.314	0.206 → 0.256	except_0 전용 disc와 동등 이상 (0.306 / 0.245): 인접행렬 직접 참조 discriminator(edge-existence 조회 + GraphSAGE)가 한 번도 본 적 없는 시나리오로 전이 — 실험 2.1의 일반화 가설 지지

6.3 Proposal 온도 (동반 문서 §6 처방 (i); fam 0.05, 1%, data disc)

blk	τ	arrival	valid	rem-path	ESS/100
4	1.0	0.948	0.306	0.651	99.1
	1.5	0.910	0.285	0.639	98.3
	2.0	0.853	0.236	0.615	97.1
16	1.0	0.885	0.245	0.625	97.9
	1.5	0.834	0.218	0.602	97.1

	2.0	0.729	0.147	0.586	97.0
--	-----	-------	-------	-------	------

6.4 발견

- **Absorbing 커널 instantiation은 기계적으로 작동한다.** 이전에 관측된 weight 분산 폭발이 재발하지 않음(bounded logit + label smoothing + negative 커버리지); 부분 경로에 대한 disc 검증 정확도 0.71-0.88; 모든 block size에서 **일관되게** validity +4-5%p, EM/PC +3-5%p, arrival 불변.
- **그러나 효과는 작고, 원인이 이제 추측이 아니라 측정이다:** ESS $\approx 94-99 / 100$. mean-field 후보 100개가 near-clone이라 가중치가 거의 평평 — MASKED_GUIDANCE.pdf §6이 예측한 proposal entropy 범목이 BD의 모든 block size에서 실측됨. 제거 edge 사용률이 거의 불변($0.66 \rightarrow 0.65$)인 것이 그 증거: 재가중은 제시된 후보 중에서만 고를 수 있는데, 제거 edge를 피하는 후보가 거의 제시되지 않는다.
- **unseen 시나리오 일반화(실험 2)가 가장 명확한 긍정 결과:** except_0을 본 적 없는 disc가 전용 disc와 동등(약간 우위)하게 guidance한다. 시나리오 정보는 암기된 경로가 아니라 인접행렬 조희 피처를 통해 들어간다.
- **Proposal 온도를 올리는 것은 얻는 것보다 잃는 것이 크다:** rem-path $-2 \sim -6\%$ 에 arrival $-4 \sim -17\%$; ESS는 여전히 ≈ 97 . 같은 proposal을 평평하게 만드는 것으로는 부족하다.
- **시사점.** 재가중 기계는 검증됐고, 범목은 proposal이다. 자연스러운 다음 단계는 discriminator를 유지한 채 후보 생성기를 바꾸는 것: (i) A_{scn} 하의 adjacency-masked proposal (동반 문서 처방 (ii)) — 제거 edge를 아예 쓸 수 없는 후보들 위에서 IW guidance가 합법적 우회로를 선택; 그리고/또는 (ii) 시나리오 그래프 기준의 P1형 splice와 discriminator의 채점 측 활용.

6.5 Adjacency-masked proposal (Lemma 3) — 범목 해소의 실측

§6.1과 같은 프로토콜에, 후보 proposal을 공개된 이웃 기준 시나리오-합법 전이로 마스킹 (BD_GUIDANCE_FORMULATION.pdf §6: 이상적 discriminator 하에서 정확 — 제외되는 후보는 target 가중치가 0). adj-only = discriminator 없이 마스킹만 (제약 자체의 효과 분리용 컨트롤).

blk	변형	arrival	valid (exc)	valid ^ hit (raw)	rem-path	rem-edge	EM	PC
4	base	0.939	0.253	0.239	0.661	0.051	0.231	0.240
	guided (§6.1)	0.948	0.315	0.290	0.651	0.050	0.281	0.296
	adj-only	0.873	0.316	0.270	0.502	0.030	0.275	0.291
	adj+guided	0.868	0.368	0.316	0.495	0.030	0.316	0.337
8	base	0.944	0.242	0.229	0.656	0.050	0.211	0.223
	guided	0.936	0.293	0.271	0.646	0.050	0.272	0.281
	adj-only	0.863	0.296	0.257	0.489	0.031	0.250	0.267
	adj+guided	0.868	0.338	0.292	0.487	0.031	0.300	0.315
16	base	0.896	0.206	0.181	0.642	0.049	0.177	0.188
	guided	0.884	0.250	0.215	0.630	0.048	0.214	0.228
	adj-only	0.822	0.264	0.208	0.486	0.031	0.212	0.232
	adj+guided	0.809	0.295	0.230	0.467	0.030	0.246	0.265
32	base	0.897	0.165	0.153	0.657	0.050	0.136	0.147
	guided	0.878	0.205	0.169	0.649	0.050	0.165	0.181
	adj-only	0.832	0.212	0.172	0.486	0.031	0.161	0.181
	adj+guided	0.817	0.238	0.183	0.504	0.033	0.180	0.202
64	base	0.864	0.164	0.151	0.634	0.048	0.131	0.145
	guided	0.882	0.204	0.183	0.635	0.048	0.157	0.175
	adj-only	0.805	0.204	0.168	0.488	0.031	0.153	0.173
	adj+guided	0.818	0.243	0.193	0.480	0.030	0.179	0.205

Pivot: fam 0.1 adj+guided — blk4 valid 0.096 $\rightarrow$ 0.165, rem-path 0.868 $\rightarrow$ 0.716 (arrival 0.95 $\rightarrow$ 0.80); blk16 valid 0.057 $\rightarrow$ 0.126. 실험 2 disc + adj proposal: blk4 valid 0.366, blk16 0.295 — except_0 전용 disc(0.368 / 0.295)와 구분 불가: proposal을 바꿔도 일반화가 유지됨.

- **범목은 정말 proposal이었다.** 마스킹만으로(adj-only) 제거 edge의 edge 단위 비율이 절반($0.050 \rightarrow 0.030$), rem-path가 0.66 $\rightarrow$ ~ 0.49 — 재가중이 이루지 못한 폭. 결합(adj+guided) 시 baseline 대비 validity 총 +9-12%p (blk4: 0.253 $\rightarrow$ 0.368, 상대 +45%), EM 상대 +37%.
- **이론이 예측한 그대로의 분업:** 제거 edge 회피는 마스킹(proposal)이 담당 — discriminator는 rem-path를 더 줄이지 못함(~ 0.49 유지) — 재가중은 합법 후보들 위에서 경로 품질을 추가(모든 블록에서 adj-only 대비 valid +4-5%p, EM +0.03-0.04). Lemma 3의 “마스킹은 가중치 0인 후보를 삭제하고, D는 생존자를 순위 매긴다”가 데이터에 그대로 보인다.

- **비용은 arrival (-4~-9%p):** 불법 지름길이 막힌 모델이 때로 방향하다 miss로 끝난다. §5의 P3 endpoint patch(예외 그래프 기준)가 구조적으로 arrival = 1.0을 복원하므로, **adj+guided + A_{scn} 기준 P1/P3가 자연스러운 완성형** — 다음 단계로 남김.
- **잔여 rem-path ≈ 0.49는 Z ≈ 0 폴백에서 발생** (상호 불법인 masked 앵커가 unmasked reveal을 강제 — Lemma 3의 후보-내부 caveat) — 남은 누수는 국소적 이고 원인이 특정됨.
- **ESS는 여전히 ≈ 95-99:** 합법 후보들끼리도 near-clone. discriminator의 기여는 경로당 ~24회 reveal에 걸쳐 누적되는 작지만 체계적인 미세 조정이며, 추가 여지는 discriminator가 아니라 **합법 우회로들 사이의 diversity**(repaint식 재마asking, 혼합 proposal)에 있다.

6.6 Guided 경로의 해부와 예외 그래프 기준 후처리

사후 진단: 새 평균 400쌍, adj+guided (mix disc, N = 100); bad edge를 두 그래프 기준으로 분류; P1/P3는 예외 그래프 G_{exc} 기준으로 계산.

	blk4	blk16
bad edge (edge 단위)	4.8% (421 / 8,826)	5.9% (514 / 8,661)
— removed (normal엔 있었으나 시나리오에서 폐쇄)	2.9%	3.0%
— alien (normal 그래프에도 없던 edge)	1.9%	2.9%
bad edge ≥1개 포함 경로	62%	71%
removed 쌍의 G _{exc} 실제 우회 거리	중앙값 4 hop (≤3은 21%, 최대 15)	중앙값 4
alien 쌍의 G _{exc} 실제 거리	중앙값 5 (최대 44)	중앙값 3 (최대 45)

- **최소하지만 normal 해부(\$4.3)보다 사거리가 길다.** normal에서는 모든 bad edge가 2-3 hop 국소 스킵(중앙값 3, 91%가 ≤3)이었는데 여기서는 중앙값 4-5. 구조적 이유: removed edge를 밟았다는 건 원래 길이 있었다는 뜻이고, 폐쇄 주변의 진짜 우회로는 본질적으로 길다. alien 잔여(~2-3%)는 Z ≈ 0 폴백으로 새는 것이며 최대 44-45 hop짜리 장거리 순간이동도 소수 포함.
- **모든 bad 쌍이 수선 가능:** P1(G_{exc} 최단경로 브리지) + P3(G_{exc} 중점 패치)가 400 × 2 경로 전부에서 성공 — 수선 불가 0건.

blk	변형	arrival	valid (exc)	EM	PC	평균 패치	수선 불가
4	adj+guided raw	0.868	0.368	0.316	0.337	—	—
	+ P1+P3 (G _{exc})	1.000	1.000	0.325	0.475	5.3 토큰	0
16	adj+guided raw	0.809	0.295	0.246	0.265	—	—
	+ P1+P3 (G _{exc})	1.000	1.000	0.268	0.426	6.2 토큰	0

- **PC 급상승 (+0.14-0.16):** 삽입된 G_{exc} 최단 브리지가 실제 우회 경로와 겹침 — 패치가 단순 합법화가 아니라 경로를 정답 쪽으로 이동시킨다. 패치 비용(~5-6토큰, 경로의 ~25%)이 normal 때(+1-2)보다 큰 것은 진짜 우회로가 본질적으로 길기 때문.
- **전체 시스템 관점 (blk4):** baseline raw EM 0.231 → adj+guided + P1+P3 EM 0.325 (상대 +41%), 여기에 valid = 1 ∧ arrival = 1의 구조적 보장 — 예외 상황 대응 파이프라인의 완성형 후보. (400쌍 진단 기준; 전 block size × 1,000쌍 본 실험이 자연스러운 확장 단계.)

6.7 Negative class의 완결: 순수 모델 분포 discriminator

Eq. (2)의 분모는 "normal 데이터"가 아니라 p_g다 — 기준 **data / mix** negative는 p_g ≈ q_{normal} 가정을 깬 근사였다. 이번 라운드가 그 간극을 닫는다: block size마다 해당 체크포인트의 **unconditional 생성** 20k개(조건 dropout이 ori+dst를 동시/에 null로 학습하므로 plan(None, None)이 in-distribution)를 negative의 100%로 사용해, 블록별 이론-충실 discriminator를 만들었다 (**BDdisc_*_model_blk{B}**). disc 입력은 캔버스 형식([dst = 경로 자신의 종점, path...])을 유지해 형식 차이로 컨닝하지 못하게 했다; 잔여 근사는 unconditional p_g(x)가 OD-조건부 p_g(x | od)가 아닌 주변분포라는 점.

blk	valid: base	neg = data	neg = mix	neg = model	adj+mix	adj+model
4	0.253	0.306	0.315	0.321	0.368	0.371
8	0.242	0.286	0.293	0.297	0.338	0.343
16	0.206	0.245	0.250	0.267	0.295	0.307
32	0.165	0.199	0.205	0.222	0.238	0.253
64	0.164	0.205	0.204	0.221	0.243	0.248

valid (exc) 기준; EM/PC도 같은 순서 (예: blk32 EM 0.156 → 0.165 → 0.177 plain; adj 0.180 → 0.192). arrival, rem-path, ESS는 negative class와 무관 — discriminator는 proposal이 내놓는 것을 바꿀 수 없고 순위만 매길 수 있다.

- **이론적 순서가 단조롭게 실현됨:** 모든 block size에서, plain·adj+guided 모두 data < mix < model (10/10 비교). negative class가 진짜 분모 p_g에 가까울수록 guidance가 좋아진다.

- 이득은 블록이 클수록 커진다 (blk4는 mix 대비 +0.6%p, blk32/64는 +1.7%p): 큰 블록일수록 모델 분포가 normal 데이터에서 더 멀어지므로(\$1의 validity 감쇠) $p_{\theta} \approx q_{\text{normal}}$ 가정이 더 깨지고, 충실한 분모의 가치가 커진다.
- 현재까지 최고 수치 (adj + model-negative disc): blk4 valid 0.371 / EM 0.320 raw — baseline 0.253 / 0.231 대비 — 후처리 없이. \$6.6의 P1+P3를 없으면 valid = arrival = 1.

6.8 3자 심층 분석: base / modelD / adj+modelD, 후처리 전후

평가 1,000쌍, blk 4/16, model-negative disc; inv-node = invalid edge에 접한 생성 정점의 비율; P1/P3는 G_{exc} 기준. 새 생성 시드라 raw 값은 \$6.1/6.7 대비 통상 $\pm 1\%$ p 이내에서 다름. 전체 24행 (P1 단독 / P3 단독 포함)은 `sets_log/threeway.log`.

blk	구성	변형	arrival	valid	EM	PC	inv-edge	inv-node	rem-edge	patch
4	base	raw	0.963	0.242	0.222	0.230	6.44%	11.89%	5.07%	—
4	base	P1+P3	1.000	1.000	0.257	0.417	0%	0%	0%	6.3
4	modelD	raw	0.952	0.327	0.291	0.305	5.47%	10.19%	4.98%	—
4	modelD	P1+P3	1.000	1.000	0.306	0.461	0%	0%	0%	5.3
4	adj+modelD	raw	0.861	0.372	0.315	0.339	4.77%	8.71%	2.85%	—
4	adj+modelD	P1+P3	1.000	1.000	0.331	0.476	0%	0%	0%	5.3
16	base	raw	0.897	0.187	0.166	0.174	7.65%	13.92%	4.78%	—
16	base	P1+P3	1.000	1.000	0.204	0.375	0%	0%	0%	7.2
16	modelD	raw	0.895	0.252	0.217	0.230	7.12%	12.99%	4.77%	—
16	modelD	P1+P3	1.000	1.000	0.250	0.406	0%	0%	0%	7.2
16	adj+modelD	raw	0.822	0.288	0.241	0.258	5.87%	10.78%	2.95%	—
16	adj+modelD	P1+P3	1.000	1.000	0.283	0.435	0%	0%	0%	6.1

- 각 메커니즘이 invalid 구조를 깎는 지점 (raw 행). discriminator는 *alien* 성분(제거 아닌 invalid edge: blk4에서 1.37% → 0.49%)을 깎지만 removed edge(~5.0%)는 못 건드린다 — normal로 학습된 모델에게 그 edge는 완전히 정상으로 보이기 때문. 반면 adjacency 마스킹은 removed 성분을 절반으로(5.0% → 2.9%). 합치면 invalid-node 비율 11.9% → 8.7% (blk4), 13.9% → 10.8% (blk16).
- 후처리는 품질 순위를 평준화하지 않고 보존한다: 모든 변형에서 EM·PC 기준 base < modelD < adj+modelD (예: P1+P3 blk4 EM 0.257 < 0.306 < 0.331). 좋은 raw 경로가 좋은 최종 경로로 패치된다 — guidance와 후처리는 합성 가능하다.
- 정직한 기여 분해: 후처리만으로도(base + P1+P3) valid = arrival = 1에 EM 0.204-0.257이 확보되고, guidance 스택은 그 위에 상대 EM +29-39% (blk4 0.257 → 0.331, blk16 0.204 → 0.283), PC +14-16%를 얻는다. PC의 엔진은 P1 (+0.15-0.19: G_{exc} 브리지가 실제 우회로와 겹침); P3는 거의 공짜 (0.1-0.8토큰).
- 잔여 사항: blk16 adj+modelD에서 P1 단독은 valid 0.993 (G_{exc} 에서 연결 불가한 쌍 소수); P1+P3 조합은 1.000으로 마감.

6.9 MDLM vs. uniform-state diffusion (GDP): blk64 정면 비교

모든 경로가 한 64-블록에 들어가므로(데이터 최대 길이 59) blk64는 사실상 **full-canvas 영역**이다: mask 커널은 MDLM(고정 64-캔버스, END 패딩, PAD 블록 없음)이 되고, graph 커널 blk64 모델은 정확히 **GDP 논문**의 **uniform-state CTMC diffusion**($\langle \text{end} \rangle$ -확장 상태공간, $d = 2.0$, 100-step reverse, 인접행렬 제약 디코딩)이다. 후자를 같은 normal 데이터로 학습(49.5분)하고 \$6.8과 동일한 프로토콜을 적용했다; guided uniform 샘플러는 GDP 수식을 그대로 구현한다(매 reverse 스텝에서 MC-posterior의 $\hat{x}$ 를 $D/(1-D)$ 가중 후보 평균으로 교체; adj 시 최종 제약 디코드가 A_{exc} 에서 동작). discriminator는 각 모델 자신의 unconditional pool에서 만든 model-negative.

커널	구성	변형	arrival	valid	EM	PC	inv-edge	rem-edge	patch	ESS
mask64 (MDLM)	base	raw	0.874	0.151	0.120	0.133	8.6%	4.9%	—	—
mask64	base	P1+P3	1.000	1.000	0.193	0.361	0%	0%	7.1	—
mask64	modelD	raw	0.888	0.222	0.173	0.192	8.4%	4.8%	—	94.9
mask64	modelD	P1+P3	1.000	1.000	0.220	0.379	0%	0%	7.6	—
mask64	adj+modelD	raw	0.806	0.251	0.183	0.211	6.8%	3.0%	—	95.1
mask64	adj+modelD	P1+P3	1.000	1.000	0.234	0.401	0%	0%	6.8	—
graph64 (uniform)	base	raw	0.043	0.460	0.080	0.200	5.1%	5.1%	—	—
graph64	base	P1+P3	1.000	1.000	0.051	0.233	0%	0%	11.9	—
graph64	modelD	raw	0.018	0.645	0.144	0.307	5.2%	5.2%	—	97.1
graph64	modelD	P1+P3	1.000	1.000	0.075	0.254	0%	0%	18.7	—

graph64	adj+modelD	raw	0.007	0.985	0.220	0.463	0.0%	0.0%	—	97.1
graph64	adj+modelD	P1+P3	1.000	1.000	0.105	0.307	0%	0%	18.9	—

- **두 커널은 정반대 방식으로 실패한다.** MDLM/mask는 도착하지만(0.87) edge를 갠다(valid 0.15); uniform은 edge를 지키지만(valid 0.46, 내장 제약 디코드 덕에 alien edge 0 — 위반은 오직 removed edge뿐) 거의 도착하지 못한다(0.04, 이전 보고서의 graph 커널 프로파일 재현).
- **guidance는 uniform 커널에서 훨씬 세계 듣는다** — 동반 문서 §6의 예측 확인: 재가중만으로 valid 0.460 → 0.645 (+18.5%p; mask는 +7.1%p), 시나리오-인접 행렬 디코드까지 결합하면 **raw에서 valid 0.985, invalid edge 0.00%** — 후처리 전에 validity 문제가 사실상 해결된다. 주목할 점: ESS는 두 커널 모두 ~97 — uniform의 우위는 가중치 다양성이 아니라 **수정 가능성(revisability)**이다. 100번의 재샘플링 스텝이 작은 넋지를 복리로 누적하는 반면, mask의 비가역 reveal은 넋지 한 번 뒤 결정을 잠근다.
- **그러나 guidance는 uniform의 arrival을 사주지 못한다** (0.043 → 0.007). 후처리가 경로당 ~19토큰을 이식해야 하고(최종 경로의 절반이 패치), 합성 품질은 낮 게 남는다: EM 0.105 / PC 0.307 vs mask64의 0.234 / 0.401. P1+P3 보장 이후에도 **end-to-end 승자는 mask 커널** — arrival은 모델이 공급해야 하는데, 그것을 주는 쪽은 mask뿐이다.
- **방법론 관점의 독해:** IW guidance가 빛나는 곳은 uniform 커널(크고 메커니즘이 깨끗한 개선), 과제가 풀리는 곳은 mask 커널이다. blk64 쌍이 설계 공간의 양 끝을 보여준다 — 수정 가능하지만 길을 잃는 쪽 vs 결단력 있지만 거친 쪽 — 그리고 §6.8의 완성형(small-block mask + adj + modelD + P1/P3)이 여전히 최적 운용점 이다.

uniform 커널의 경로가 실제로 끝나는 곳 (400쌍 진단, 미도달 경로의 종착점→dst G_{exc} hop 거리):

	arrival	중앙값 hops	평균	≤5 hops	생성 길이 (실제 24.1)	len corr
mask64 (참고, §4.2 프로파일)	0.87	1	~2	98%	~ 실제	0.99
graph64 base	0.040	5	8.6	53%	18.4	0.735
graph64 adj+modelD	0.005	17	19.1	12%	9.7	0.166

- **질적으로 다른 세 가지 실패.** mask의 miss는 문 앞 토큰 식별 실수(중앙값 1 hop); 순수 uniform은 *동네에서 길을 잃음*(중앙값 5 hop, 길이 부족 18.4 vs 24.1); guided+제약 uniform은 *중간에 포기* — dst에서 중앙값 17 hop, 실제 길이의 40%(9.7토큰, len corr 0.17)에서 종료.
- **조기 종료의 메커니즘:** 제약 디코드에서 모든 이동은 직전 정점의 이웃으로 마스킹되는데 <end> 상태는 항상 합법이다. x_t 의 질량이 이웃 아닌 정점들에 있을 때 다 마스킹 후 <end>가 상대적으로 커져 걷기가 끝난다. 따라서 uniform의 대표 수치 valid = 0.985는 완벽히 합법적인 *반쪽 산책*이다 — validity를 arrival-by-length로 지불한 것으로, P3가 ~19토큰을 이식해야 했고 합성 EM이 낮게 남은 이유가 정확히 이것이다. 이는 §6.9의 판정을 더 선명하게 한다: mask의 "결단력 있지만 거친" 실패가 수리 비용이 더 싼 쪽이다.

6.10 Forward 커널 ablation: GDP graph-CTMC vs. 순수 uniform-state (D3PM)

두 forward 커널. GDP의 커널은 *도로 그래프를 따라 확산*한다: (<end>-확장) 인접행렬로 만든 generator $G = A' - D'$ 로

$$Q_t^{graph} = \exp((A' - D') \beta_t) \text{ — 국소 이동, 느린 전역 혼합(작은 스펙트럴 갭), } x_t \text{에 그래프 구조가 보존됨.}$$

고전적인 순수 uniform-state 커널은 완전 그래프 특수 사례 $A' = \mathbb{1}\mathbb{1}^T$ 이며 닫힌 형태를 갖는다:

$$Q_t^{unif} = e^{-K\beta_t} I + (I - e^{-K\beta_t}) \mathbb{1}\mathbb{1}^T / K \Leftrightarrow \bar{\alpha}_t = e^{-K \sum_{s \leq t} \beta_s} \text{인 D3PM-uniform (} K = V+1 \text{ 상태)},$$

즉 생존-또는-균등-순간이동 — 그래프 구조가 어디에도 없다. 같은 Destroyer에 완전 그래프를 넘겨 구현; 완전 그래프의 스펙트럴 갭이 K라 원래 스케줄이면 t = 2에 완전히 섞이므로 β 를 1/K로 스케일($7 \times 10^{-8} \dots 7.2 \times 10^{-3}$)해 스텝당 생존 프로파일을 graph 커널과 정렬; connectivity loss는 끄고 내장 제약 디코드는 완전 그래프라 자동 무제약 — 구성상 "순수" 세팅. 백본·데이터·1 epoch 예산(48.9분)·D3PM ELBO·blk64(=full canvas)·§6.8 프로토콜 전부 동일.

구성	변형	arrival	valid	EM	PC	inv-edge	rem-edge	patch	ESS
base	raw	0.086	0.001	0.001	0.001	82.9%	0.9%	—	—
	P1+P3	1.000	1.000	0.002	0.032	0%	0%	58.8	—
modelD	raw	0.092	0.006	0.005	0.006	82.3%	1.0%	—	91.3
	P1+P3	1.000	1.000	0.017	0.048	0%	0%	58.0	—
adj+modelD	raw	0.002	0.967	0.084	0.342	0.0%	0.0%	—	91.3
	P1+P3	1.000	1.000	0.066	0.250	0%	0%	20.2	—

- **순수 uniform 커널은 이 과제에서 붕괴한다:** raw valid 0.001, invalid edge 82.9% — 거의 전부 *alien*(rem-edge는 0.9%뿐)으로, 사실상 무작위 정점 수열이다. P1이 경로당 53토큰(경로 길이의 3배)을 이식해야 하고 어떤 처리를 해도 $EM \leq 0.07$. 같은 예산의 graph forward는 valid 0.460, inv-edge 5.1% — **GDP의 그래 프-구조 forward가 uniform-state diffusion을 성립시키는 요소**이며, 노이즈의 국소성은 장식이 아니라 0.46과 0.001의 차이다.
- **guidance는 이를 구하지 못하며, 그 이유가 negative-class 설계에 교훈을 준다:** model-negative disc는 학습 정확도 0.999(자기 negative — 모델의 unconditional 샘플 — 가 자명하게 구분되는 쓰레기라서)에 도달하지만 실제 경로에는 **우연 수준(0.527)**으로만 전이된다. D가 "예외인가?"가 아니라 "무작위 수열

- 인가?”를 배운 것이다. p_0 가 데이터 매니폴드에서 아주 멀면 Eq. 2의 분포 클래스가 정작 필요한 곳에서 신호를 갖지 못한다 — data/mix negative가 더 잘 다룰 옛지 케이스.
- **하드 제약만이 유일한 지렛대:** A_{exc} -제약 디코드가 validity를 0.967로 올리지만, 걷기는 graph64보다 더 길을 잃는다 (endpoint patch 20토큰; 합성 EM 0.066, 세 커널 중 최하).
 - **Full-canvas 커널 순위** (raw valid / P1+P3 후 EM): mask64 0.15 / 0.234 · graph64 0.46 / 0.105 · uniform64 0.001 / 0.066 — forward의 구조는 validity를 사고(graph > mask > uniform), 디코딩의 결단력은 arrival과 최종 품질을 산다(mask >> graph >> uniform).

6.11 발표된 baseline과의 비교: D-CBG (Schiff et al.)

kuleshov-group/discrete-diffusion-guidance 의 plug-in 이식 (이 저장소 파일 수정 0건; dcbg_plugin.py 가 그들의 _cbg_denoise 로직을 담음): **노이즈-조건 분류기** $p(y \mid x_t, t)$ — 그들 프로토콜: 라벨된 데이터(exceptional vs normal, 같은 1% 예산/split)를 생성 시점 forward corruption으로 오염 — 가 posterior를 $y \cdot \log p(y \mid x_t^{\ell \rightarrow k})$ 로 기울인다. mask 커널: 공개 위치에서의 **exact 열거**(first-hitting 하에서 정확; reveal당 |V|회 분류기 호출); graph 커널: 그들의 **1차 (Taylor) 근사**. $y \in \{1, 2, 4\}$; 평가 동일.

구성	방법	arrival	valid	EM raw	rem-edge	inv-edge	EM P1+P3	PC P1+P3	s/path
mask blk4	base	0.963	0.242	0.222	5.1%	6.4%	0.257	0.417	0.01
	D-CBG $\gamma=4$ (최적 γ)	0.907	0.267	0.248	2.2%	9.0%	0.309	0.436	2.7
	우리 (IW, modelD)	0.952	0.327	0.291	5.0%	5.5%	0.306	0.461	0.03
	우리 (adj+modelD)	0.861	0.372	0.315	2.9%	4.8%	0.331	0.476	0.05
mask blk64	base	0.874	0.151	0.120	4.9%	8.6%	0.193	0.361	0.01
	D-CBG $\gamma=4$	0.844	0.156	0.124	2.2%	9.6%	0.228	0.386	2.7
	우리 (adj+modelD)	0.806	0.251	0.183	3.0%	6.8%	0.234	0.401	0.09
graph blk64	base	0.043	0.460	0.080	5.1%	5.1%	0.051	0.233	0.06
	D-CBG $\gamma \in \{1, 2, 4\}$	0.025	0.459-0.470	0.085	5.0%	5.0%	0.054	0.235	2.8
	우리 (adj+modelD)	0.007	0.985	0.220	0.0%	0.0%	0.105	0.307	0.09

분류기 검증 정확도 (그들 프로토콜, 생성 시점 corruption 기준): mask blk4 0.719, mask blk64 0.734 — 우리 disc와 비슷 — 그러나 **graph/CTMC는 0.512 (우연 수준)**: uniform-CTMC로 오염된 경로에서 노이즈-상태 분류기가 이 데이터 예산으로는 학습되지 않아 graph D-CBG는 무력(해당 행 ≈ base). 우리의 클린 부분-경로 discriminator(Lemma 1 정식화)는 노이즈-상태 분류 자체를 우회한다.

- **D-CBG가 진짜 강한 지점:** 위치별 열거 덕에 removed edge를 직접 벌줄 수 있다 — $\gamma = 4$ 에서 비-인접행렬 방법 중 최저 removed-edge율(2.2%, 우리 순수 재가 중 5.0% 대비). 단 $\gamma = 4$ 는 되어야 작동한다 ($\gamma \leq 2 \approx \text{base}$).
- **그 대가:** 위치별 tilting이 모델의 결합분포와 싸우면서 전체 invalid edge가 증가(blk4: 6.4% → 9.0%; removed가 alien으로 대체됨)하고 arrival이 하락. 우리의 joint 후보 재가중은 후보가 구성상 모델-일관적이라 validity와 EM이 **함께** 개선된다.
- **End-to-end에서는 모든 셀에서 우리가 우세:** blk4 합성 EM/PC 0.331/0.476 (우리) vs 0.309/0.436 (D-CBG 최적 γ); blk64·graph64도 동일 — 그것도 **guidance 비용 30-90배 절감**(0.03-0.09 vs exact 열거 ≈2.7 s/path)으로.
- **시나리오 전이:** D-CBG 분류기는 인접행렬을 입력받지 않아 새 시나리오마다 재학습이 필요; 우리 discriminator는 unseen 시나리오로 일반화(§6.2, 실험 2) — 논 문 비교표가 가져야 할 열.

6.12 통제된 2×2: 메커니즘 × 분류기, 나머지 전부 일치

§6.11은 guidance **메커니즘**과 분류기 **설계**가 교락되어 있었다. 이번 라운드는 이를 통제한다: 네 셀 모두 동일한 분류기 아키텍처(임베딩 · GraphSAGE · edge-existence/deg-ratio 채널 · 인코더 · masked pooling · bounded logit · label smoothing)와 동일한 학습 프로토콜(라벨 데이터: exceptional 1% vs normal, 같은 split)을 공유한다. 남은 차이는 방법 내재적인 것뿐: D-CBG의 분류기는 수식이 요구하는 대로 **노이즈** 상태 (x_t, t)를 읽고, 우리는 Lemma 10이 요구하는 대로 **클린 부분** 경로를 읽는다 — 그리고 출력의 사용 방식(위치별 tilting vs joint 후보 재가중). 2×2에는 proposal 마스킹 없음(별도의 합성 가능한 레버로 유지).

구성	셀	clf val	arrival	valid raw	inv-edge	rem-edge	EM P1+P3
mask blk4	D-CBG + plain ($\gamma=4$)	0.719	0.907	0.267	9.0%	2.2%	0.309
	D-CBG + adj ($\gamma=4$)	0.746	0.939	0.289	6.1%	4.4%	0.290
	IW + plain	0.676	0.948	0.255	6.4%	4.9%	0.271
	IW + adj	0.71	0.948	0.306	5.8%	5.0%	—
mask blk64	D-CBG + plain ($\gamma=4$)	0.734	0.844	0.156	9.6%	2.2%	0.228
	D-CBG + adj ($\gamma=4$)	0.750	0.844	0.181	8.4%	3.5%	0.214
	IW + plain	0.676	0.883	0.172	8.6%	4.6%	0.204

	IW + adj	0.71	0.876	0.205	—	—	—
graph blk64	D-CBG + adj (모든 γ)	0.531	0.03	0.466-0.469	5.0%	5.0%	0.056
	IW + adj (data)	0.71	0.015	0.656	5.0%	5.0%	0.080
	IW + plain (ESS 31!)	0.676	0.019	0.708	4.1%	4.1%	0.084

IW 행은 guidance만(proposal 마스크 없음); "IW + adj" 셀은 \$6.1의 data-negative 런 재사용(그 런에서는 합성 EM 미측정). 모든 구성에서 $\gamma \leq 2$ 의 D-CBG는 $\approx$ base. 합성 가능한 adjacency-masked proposal을 없으면 IW + plain이 blk4에서 valid 0.327, 그리고 graph64의 새로운 최고 기록 — valid **0.988**, raw **EM 0.233** (IW + plain + adj-proposal) — 에 도달한다.

- **사용자 가설이 실증됨: adjacency-aware 분류기는 두 방법 모두를 돕는다.** D-CBG는 두 block size에서 valid +2.2-2.5%p (clf val 0.72 $\rightarrow$ 0.75), 그리고 더 흥미롭게도 adjacency 채널이 *D-CBG의 일관성 손상을 제거*한다 (blk4 inv-edge 9.0% $\rightarrow$ 6.1%): 합법성을 직접 보게 되니 alien edge를 만들어내던 극단적 tilt가 불필요해진다.
- **분류기를 맞추면 두 메커니즘의 격차는 \$6.110이 시사한 것보다 좁다:** adj-vs-adj에서는 IW 승(0.306 vs 0.289; 0.205 vs 0.181); plain-vs-plain은 갈림(blk4는 D-CBG 0.267 > IW 0.255; blk64는 IW 0.172 > D-CBG 0.156). 따라서 메커니즘 수준에서 IW의 정확한 주장은: 조정할 γ 가 없음(D-CBG는 $\gamma = 4$ 미만에서 무력), arrival 보존(0.95 vs 0.84-0.94), 30-90배 낮은 비용, proposal 마스크와의 자유로운 합성.
- **구조적 논거는 통제 후에도 생존:** adjacency 아키텍처를 맞춰도 D-CBG의 분류기는 CTMC 커널에서 우연 수준(0.531) — 병목은 아키텍처가 아니라 *노이즈-입력 분류 문제 자체*이며, 이를 우회하는 클린-부분-경로 입력은 IW 정식화(Lemma 1)에서만 가능하다. graph 커널에서 메커니즘 격차는 결정적: 0.47 (D-CBG) vs 0.71 (IW).
- **예상 밖의 발견:** graph 커널에서는 PLAIN 부분-경로 discriminator가 adjacency-aware보다 잘 유도한다 (valid 0.708 vs 0.656), 그것도 극적으로 날카로운 가중치(ESS 31 vs 96 — 이 프로젝트 전체에서 처음 관측된 50 미만 ESS)로. adjacency 피처가 정적 시퀀스-수준 단서가 판별 신호인 지점에서 후보 점수를 균질화하는 것으로 보인다; 설계 규칙을 끌어내기 전에 전용 ablation이 필요하다.

7. 이전 보고서(RESULTS_BD_prev.pdf)와의 관계

- 이전 보고서는 blk4만, refine 변형과 함께 평가: mask raw 0.952 arrival / 0.820 valid $\wedge$ hit, refine_es +0.03 arrival, refine_nx는 구조상 arrival 1.0. 본 sweep은 refine을 전부 제거(사용자 요청)하고 block size를 변화시켰다.
- 이전 보고서의 "mask 커널에는 refinement가 거의 불필요"라는 결론은 여기서 더 강해진다: blk1의 raw arrival 0.997 — refinement의 여지가 $\leq 0.3\%$ p.
- graph(uniform-state CTMC) 커널은 이 sweep에 포함되지 않았다(사용자 결정: mask만). 이전 보고서의 대기 작업($d = 0.05$ 재학습, respaced block sampling)은 미결로 남는다.

산출물

- 체크포인트: `sets_model/BD_porto_v3_normal_mask_blk{1,2,4,8,16,32,64}_base_bd.pth` (+ `_epoch_0`), 서버 `143.248.84.179:/home/aailab/wp03052/Synthetic-Data/Block-Diffusion-0D-Planning`
- 결과: `sets_res/BD_porto_v3_normal_mask_blk*_base_bd.res` (raw + refine_nx + refine_es 저장; 본 보고서는 raw만), 후처리 비교 `sets_res/BD_mask_blk*_postproc.res` (`eval_bd_postproc.py`) + 경로별 EM/PC 기록 `sets_res/em_pc/`
- 학습 로그: `sets_log/bd_mask_blk*.log`, `sets_model/*_bd_train_log.txt`
- 코드: `models_seq/bd_models.py`, `models_seq/bd_trainer.py`, `main_bd.py`, `train_porto_bd.sh`; 실행: tmux 세션 `bd_gpu{0..3}` (GPU 당 1런)
- Guidance: discriminator `sets_disc/BDdisc_*.pth` + pool `sets_disc/neg_pool.pth`; 결과 `sets_res/BDguid_*.res`; 코드 `models_seq/bd_disc.py`, `bd_models.py::plan_guided`, `train_bd_disc.py`, `eval_bd_guidance.py`, `run_bd_guidance_all.sh`
- 문서: 코드 검증 `pdfs/BD_CODE_VERIFICATION_K0/EN.pdf`; guidance 수식 `pdfs/BD_GUIDANCE_FORMULATION.pdf`; 본 보고서 영어판 `pdfs/RESULTS_BD.pdf`