

Block-Diffusion OD Planning — 통합 결과 (v3)

상태 (2026-07-20, v3). 본 문서의 모든 수치는 v2 백본(시드된 80/20 split로 재학습한 14개 모델: mask×7, graph d=2.0×7) 기준으로 재측정되었다. 평가: normal 과제는 학습에 쓰이지 않은 test split에서 추출한 공유 held-out 1,000쌍(52는 생성 시드 3개 mean±std), 예외 과제는 discriminator 학습에서 제외된 except_0 예외 1,000쌍. 발전 과정과 전체 ablation 서사는 RESULTS_BD_v1.pdf (아카이브)에, 수식 전문은 BD_GUIDANCE_FORMULATION.pdf · BD_CODE_VERIFICATION_K0/EN.pdf · BD_ARCHITECTURE_K0.pdf 에 있다. v1 체크포인트·disc는 v1_* 로 아카이브.

1. 설정과 아키텍처

BD3-LM식 block diffusion (블록 간 semi-AR, 블록 내 이산 diffusion), 6층/dim 256 DiT(adaLN), porto.v3.normal (정점 1,390, 경로 193만), 1 epoch = 48.2k iter (bs 32, lr 5e-4). 캔버스 [dst, ori, v..., v_L=dst, END...] : END tail은 dst 블록 내 학습 대상, PAD 블록 제외. 커널: mask(absorbing, SUBS, first-hitting — 데이터 최대 길이 59라 blk64는 사실상 MDLM)와 graph(uniform-state CTMC, d=2.0, T=100). 생성은 open-ended (dst→hit / END→miss).

그림 1. Block-diffusion 동작 원리 — 특히 이전 블록 정보의 유입 경로 (코드 세부와 라인 번호: pdfs/BD_ARCHITECTURE_K0.pdf)

A. 캔버스와 길이 스펙 (blk4 예시; build_canvas)



노랑 = 클린 조건 prefix (loss 제외); END tail은 dst 블록 내부에서 학습 대상; PAD 블록은 loss 제외.

B. 이전 블록 정보의 유입 = self-attention 단일 경로

	B1	B2	B3	B1'	B2'	B3'
B1	BD	.	.	.	.	.
B2	.	BD	.	OBC	.	.
B3	.	.	BD	OBC	OBC	.
B1'	.	.	.	BD	.	.
B2'	.	.	.	BC	BD	.
B3'	.	.	.	BC	BC	BD


	B1	B2	B3*
B1	✓	.	.
B2	✓	✓	.
B3*	✓	✓	✓


왼쪽 (학습, get_block_diff_mask): $[x_t(B1-B3) \parallel x_0(B1'-B3')]$ 입력에서 노이즈 블록 B3의 쿼리는 자기 블록(BD)과 이전 블록들의 클린 x_0 (OBC — 이전 블록 정보의 유입한 학습 토큰)만 본다. BC는 클린 절반의 표현 유지용.

오른쪽 (샘플링, get_block_causal_mask): 현재 블록 B3*의 모든 토큰이 커밋된 B1, B2를 매 레이어에서 직접 attend (주황 강조). 커밋 토큰은 동결($t=0$)이며 KV 캐시 없이 매 forward 재인코딩.

adaLN 조건 경로($c = t + OD$ 임베딩)는 이전 블록의 내용을 나르지 않는다 — 내용은 100% attention으로 흐른다.

C. BDTransformer 타워 — 아래에서 위로 읽기; 조건과 이전 블록 내용의 정확한 주입 지점





- γ, β, α 는 모델 파라미터가 아니다. 학습 파라미터는 보라색 adaLN MLP의 가중치(zero-init → 초기엔 전 블록 항등)이고, $\gamma/\beta/\alpha$ 는 그 MLP가 토큰·샘플마다 c에서 계산하는 활성값이다. 조건은 가중치를 바꾸지 않고 정규화된 활성값을 feature별 scale(1+ γ)/shift(β)하고 서브레이어 출력을 gate(α)한다 — LN0 affine-free인 이유.
- 이전 블록의 내용은 adaLN이 아니라 attention의 K/V로 들어온다 (파란 박스). 요약: 내용은 K/V로, 조건(블록별 t-OD)은 $\gamma\beta\alpha$ 로.

```
(γ1, β1, α1, γ2, β2, α2) = adaLN_MLP(c).chunk(6) # BDBlock.forward, bd_models.py:149-153
x = x + α1 ⊗ Attn( (1+γ1)⊗LN(x) + β1 , attn_mask )
x = x + α2 ⊗ MLP ( (1+γ2)⊗LN(x) + β2 )
```

D. Open-ended semi-AR 생성: 블록 append → first-hitting으로 토큰 1개씩 공개(공개 토큰은 즉시 다음 forward의 문맥) → 커밋 블록 스캔: dst → hit(정지) / END → miss(정지) / 아니면 다음 노이즈 블록 append.

학습의 OBC(노이즈→클린 과거)와 샘플링의 커밋-참조가 정확히 대응하도록 설계되어 (teacher forcing), 학습·생성의 조건화 분포가 일치한다. blk1에서는 모든 정보가 커밋-참조로만 흘러 causal LM이 되고, blk64(=MDLM)에서는 OBC가 공집합이 된다 — block size가 두 통로의 비율을 보간한다 (\$6.9).

2. Block size sweep — held-out, 시드 3개 mean±std

2.1 mask

blk	hit (=arr)	valid	valid∧hit (raw)	EM	PC	DTW	len err	len corr
1	0.997±.002	0.934±.007	0.934±.007	0.830±.011	0.869±.010	0.032	0.84	+0.864
2	0.958±.007	0.842±.006	0.822±.006	0.769±.005	0.799±.005	0.038	0.45	+0.982
4	0.958±.001	0.836±.004	0.811±.004	0.747±.010	0.783±.008	0.037	0.37	+0.991
8	0.951±.002	0.808±.006	0.774±.006	0.716±.008	0.754±.007	0.042	0.40	+0.993
16	0.898±.006	0.680±.006	0.625±.002	0.607±.009	0.637±.008	0.061	0.56	+0.989
32	0.858±.010	0.474±.004	0.420±.002	0.413±.002	0.437±.002	0.081	0.96	+0.968
64	0.839±.005	0.430±.014	0.373±.010	0.366±.012	0.391±.012	0.072	0.89	+0.988

2.2 graph (d = 2.0)

blk	hit (=arr)	valid	valid∧hit (raw)	EM	PC	DTW	len err	len corr
1	0.429±.001	1.000±.000	0.429±.001	0.093±.006	0.168±.007	0.437	36.4	+0.237
2	0.173±.014	0.997±.001	0.173±.014	0.399±.008	0.558±.005	0.488	6.48	+0.492
4	0.128±.007	0.978±.002	0.128±.007	0.309±.012	0.499±.008	0.302	4.50	+0.719
8	0.058±.004	0.991±.001	0.058±.004	0.124±.012	0.331±.006	0.282	4.53	+0.783
16	0.029±.002	0.996±.002	0.029±.002	0.148±.008	0.390±.006	0.377	5.66	+0.705
32	0.035±.002	0.969±.002	0.035±.002	0.174±.002	0.411±.004	0.394	5.96	+0.693
64	0.027±.004	0.966±.003	0.027±.004	0.198±.006	0.430±.001	0.363	5.74	+0.724

2.3 실패 해부 (v3, held-out 400쌍)

blk	hit	len corr (hit)	len corr (miss, n)	miss→dst 중앙 hop	≤2 hops	inv-edge	경계/내부
4	0.943	0.996	0.958 (23)	2	87%	1.04%	15 / 77
16	0.922	0.995	0.896 (31)	2	84%	1.84%	4 / 158
64	0.843	0.993	0.968 (63)	1	86%	4.70%	0 / 409

- miss는 near-miss: 총착점이 dst에서 중앙값 1-2 hop (84-87%가 ≤2) — 마지막 토큰 식별 실패이지 내비게이션 실패가 아님. 길이 보정은 hit(0.99+)-miss(0.90-0.97) 모두 유지 — dst-절단 기하 + END 보정.
- validity 하락 = 최소 국소 스킵의 경로 단위 증폭: edge 오류율은 blk64에서도 4.7%뿐이고(중앙값 3-hop 스킵), 오류는 전부 블록 내부(blk64: 경계 0 / 내부 409) — first-hitting의 블록 내 무작위 공개 순서가 원인. 블록 경계 전이(=AR형)는 무결.
- graph 커널은 거울상: 제약 디코드로 validity 0.97-1.00이지만 arrival이 0.43→0.03으로 붕괴, 길이에 따라 감소. mask는 blk1-16에서 horizon 감소 없음. 커널별 비용: mask는 validity로, graph는 arrival로 지불.
- held-out 검증: v2 수치가 v1(train 중첩 가능)과 노이즈 이내 일치 — 암기 인플레이션 없음.
- 미실험 노트: END tail의 loss 비중이 (B-1)/2로 커져 blk64에서 감독 토큰의 ~58%가 END — 상수-질량 재가중/첫-END-만 등 loss engineering 여지 (v1 \$4.5).

3. 후처리: P1 (local splice) · P3 (endpoint patch)

P1: invalid 쌍 (u,v)마다 최단경로 삽입 → valid = 1 보장, hit 불변. P3(=refine_nx): miss 중점에서 dst까지 graft → arrival = 1 보장. hit은 항상 후처리 전 측정(valid∧hit (raw)) — P1+P3 하에서 남은 유일한 모델 의존량.

blk	raw arr	raw valid	valid∧hit (raw)	raw EM	raw PC	P1+P3 EM	P1+P3 PC	패치
1	0.997	0.934	0.934	0.832	0.871	0.849	0.898	1.0
2	0.956	0.852	0.826	0.779	0.810	0.804	0.869	0.5

4	0.954	0.823	0.798	0.734	0.771	0.768	0.846	0.8
8	0.954	0.827	0.794	0.728	0.769	0.768	0.848	0.7
16	0.909	0.705	0.647	0.617	0.651	0.662	0.766	1.9
32	0.871	0.462	0.408	0.397	0.422	0.503	0.642	3.3
64	0.853	0.441	0.390	0.379	0.403	0.533	0.661	3.5

- P1+P3는 모든 블록에서 valid = arrival = 1의 구조적 보장을 주고, 사용 가능 경로 비율 = raw hit. 큰 블록에서 P1이 EM/PC도 올린다(blk64 EM 0.379→0.533) — 브리지가 실제 경로 조각이어서. 수선 불가 쌍 0건.

4. Importance-weight guidance (예외 상황 except_0)

수식 요약 (전문: BD_GUIDANCE_FORMULATION.pdf). 블록 b의 guided reverse: $q(x_{t-1}^b|x_t^b, x^{<b}) = \mathbb{E}_{x \sim \tilde{p}}[w \cdot q(\cdot|x_t)]/E[w]$, $w = q(x_0|x^{<b})/p_\theta(x_0|x^{<b}) \approx D/(1-D)$. **Lemma 1**: $w = C^{-1} \cdot r(x^{<b} \| x_0)$, $C = q(x^{<b})/p_\theta(x^{<b})$ 는 후보-독립 상수라 자기정규화에서 소거 — **클린 부분-경로** discriminator로 충분. **Lemma 2**: 블록만 보는 분류기는 marginal ratio를 배워 편향(상수 아님 → 미소거). **Lemma 3**: 후보 proposal을 공개-이웃 기준 A_{scn} -합법 전이로 마스킹해도 정확 — 제외 후보는 $\text{supp}(q)$ 밖이라 $w=0$ 인 항뿐이고 Z_t 는 후보-공통이라 소거 (비편향 분산 감소). 구현: first-hitting reveal마다 mean-field 후보 $N=100$, $w=\text{exp}(\text{bounded logit})$, 매 reveal 적용, ESS 로깅. Discriminator: GraphSAGE+edge-existence 채널(시나리오 인접행렬 입력 → 재학습 없는 시나리오 전이), negative = 해당 블록 모델의 unconditional 생성 20k($E(q)$ 의 분모 p_θ 그대로; data<mix<model 서열은 v1 §6.7).

4.1 Seen (except_0으로 disc 학습, 1%)

blk	base valid	base EM	IW valid	IW EM	IW P1P3 EM	IW P1P3 PC	ESS	adj+IW valid	adj+IW EM	rem-edge	adj+IW P1P3 EM	adj+IW P1P3 PC
4	0.266	0.240	0.331	0.298	0.309	0.464	99.1	0.390	0.338	3.0%	0.357	0.496
8	0.231	0.212	0.298	0.264	0.294	0.453	98.8	0.346	0.298	3.2%	0.335	0.483
16	0.222	0.198	0.277	0.240	0.268	0.423	98.2	0.327	0.270	3.1%	0.295	0.447
32	0.160	0.132	0.225	0.184	0.216	0.376	97.5	0.255	0.203	3.2%	0.236	0.398
64	0.141	0.129	0.201	0.160	0.211	0.372	95.4	0.229	0.176	3.1%	0.230	0.394

4.2 Unseen (except 1-99로 disc 학습 → except_0 평가)

blk	IW valid (unseen/seen)	adj+IW valid (unseen/seen)	adj+IW P1P3 EM (unseen/seen)
4	0.325 / 0.331	0.382 / 0.390	0.348 / 0.357
16	0.270 / 0.277	0.321 / 0.327	0.299 / 0.295

- 분류**: 제거 edge 회피는 Lemma 3 마스킹이(rem-edge ~5%→3%), 경로 품질은 disc 재가중치(+5~7%p valid) 담당. ESS ≈ 95-99: 스텝당 개입은 작지만 reveal 전반에 누적. 비용은 arrival ~5~7%p — P3가 구조적으로 복원.
- 일반화 격차 ≈ 0** (blk4: 0.382 vs 0.390): 시나리오 정보가 암기가 아니라 인접행렬 입력으로 들어간다는 증거. 완성형(adj+IW+P1P3)은 blk4에서 EM 0.357/PC 0.496 — baseline+P1P3(0.270/0.431) 대비 상대 +32%/+15%.

5. 발표 baseline과의 통제 비교: D-CBG (Schiff et al.)

Plug-in 이식(그들 코드 로직 그대로; dcbg.plugin.py), **분류기 아키텍처-학습 프로토콜 완전 일치**(같은 GraphSAGE+edge 채널, 같은 1% 데이터, model-negative는 같은 v2 uncond pool을 그들 방식대로 노이즈). 남은 차이는 방법 내재적인 것뿐: 노이즈-상태 입력 + 위치별 tilting (D-CBG) vs 클린 부분-경로 + joint 후보 재가중 (IW). $\gamma=4$ ($\gamma \leq 2$ 는 무력, v1 §7.1). exact 열거는 reveal당 $|V| \approx 1.4k$ 분류기 호출(≈ 2.7 s/path), first-order 근사는 저렴하나(0.07 s/path) **v2에서도 무력 재확인**(blk4 valid 0.265 ≈ base 0.266); IW는 2.4k 호출/0.03 s/path.

blk	D-CBG(data) valid	P1P3 EM	D-CBG(model) valid	P1P3 EM	IW(model) valid	P1P3 EM	adj+IW valid	P1P3 EM
4	0.301	0.295	0.309	0.302	0.331	0.309	0.390	0.357
8	0.257	0.275	0.272	0.275	0.298	0.294	0.346	0.335
16	0.249	0.263	0.258	0.252	0.277	0.268	0.327	0.295
32	0.185	0.231	0.185	0.203	0.225	0.216	0.255	0.236
64	0.163	0.222	0.173	0.209	0.201	0.211	0.229	0.230

- 모든 블록에서 IW > D-CBG** (raw valid 10/10; blk4 0.331 vs 0.309), 완성형 adj+IW가 전 셀 최고. 우리 재료 중 시나리오-조건 분류기와 model-negative는 D-CBG에도 이식되어 그들을 개선 하지만, 순서는 유지된다.
- Unseen 전이도 양쪽 성립, IW 우위 유지**: blk4 D-CBG 0.306 / IW 0.325 (seen 0.309 / 0.331). 일반화는 인접행렬-조건 분류기 설계(우리 기여, 이식 가능)의 속성.
- 비용-품질 프론티어**: 싼 D-CBG(first-order)는 작동하지 않고, 작동하는 D-CBG(exact)는 싸지 않다 — IW가 그 사이의 지배점 (30-90× 저렴, γ 튜닝 불필요, arrival 보존). uniform 커널에서는 그들의 노이즈-상태 분류기가 구조적으로 학습 불가(우연 수준)라 격차가 결정적 (v1 §7).

6. 결론과 산출물

- mask 커널의 작은 블록(1-8)이 과제를 사실상 해결하고, 남은 결함(국소 스킵·near-miss)은 P1/P3가 구조적으로 보정한다. graph 커널은 validity-arrival 트레이드의 반대극.
- 예외 상황 대응의 완성형: **adj-masked proposal + model-negative partial-path disc(IW) + P1/P3** — seen/unseen 모두에서 최고이며, 발표 baseline(D-CBG)을 모든 matched 구성에서 상회한다.
- 모델: sets_model/*_v2_bd.pth (14개; v1은 v1_archive/). 결과: sets_res/, 로그: sets_log/v3_*. 코드: bd_models.py(plan_guided), bd_disc.py, dcbg_plugin.py, train_bd_disc.py, train_dcbg_classifier.py, eval_*.py, run_v3_all.sh.