

Block-Diffusion OD Planning — Block Size Sweep (mask 커널, raw)

상태 (2026-07-19, v2). §1-§3은 v2(시드 split 재학습 14모델, held-out 공유 평가셋, 시드 3)로 전면 교체됨; graph(d=2.0) sweep 추가. mask 커널의 block size {1, 2, 4, 8, 16, 32, 64} 7종 모두 최종: 새 서버(143.248.84.179, RTX 3090 x4, GPU당 1런, 2웨이브; 런당 학습 43-54분)에서 학습·평가 완료, tmux 세션 정상 종료. 요청에 따라 이 보고서의 모든 수치는 raw — `eval_shortest.refine()` (refine_es)도, 최단경로 패치(refine_nx)도 일절 없음; 따라서 hit = arrival. 이전 보고서(blk4 단독, refine 변형 포함): RESULTS_BD_prev.pdf . 2026-07-17 갱신: §4(실패 해부), §5(후처리 P1/P3), §6(importance-weight guidance — 33런 + adjacency-masked proposal 14런, §6.5; Lemma 3 포함 수식은 BD_GUIDANCE_FORMULATION.pdf) 추가. bd3lms 원본 대비 코드 검증: BD_CODE_VERIFICATION_{K0,EN}.pdf .

설정 — swept block size를 제외하면 RESULTS_BD_prev.pdf 와 동일. BD3-LM 방식 block diffusion (블록 간 semi-AR, 블록 내 absorbing/[MASK] diffusion, SUBS 가중 CE, first-hitting 샘플링). Transformer 디노이저: 6층, dim 256, adaLN conditioning (~6.8M 파라미터). 학습 1 epoch = 48.2k iter (bs 32, lr 5e-4), 데이터 `porto_v3_normal` (index v3-0.05, 정점 1,390, 경로 193만). 캔버스는 프로젝트 길이 스펙 [dst, ori, v1, ..., v_L=dst, END...END | PAD...PAD] : dst 블록 내부의 END tail은 학습 대상, 이후 PAD 블록은 loss 제외. 조건화: dst + ori를 클린 in-context prefix 토큰으로 + OD 임베딩을 adaLN으로; 조건 dropout 0.1; CFG off (w = 1). 생성은 open-ended (`length_mode=open`): dst(hit) 또는 END(miss)가 나올 때까지 블록 추가 — 길이 모델 없음.

평가. 런당 held-out OD쌍 1,000개, open-ended, raw만. hit = 후처리 없이 dst 도달 (이 보고서에선 = arrival); validhit = 사용 가능 경로 비율; EM / PC / DTW / 길이 지표는 동반 보고서와 동일. 주의: 런마다 평가 1,000쌍을 독립적으로 추출하므로(로드 시 무시드 셔플) 런 간 ~±1%p는 표집 노이즈 이내.

그림 1. Block-diffusion 동작 원리 — 특히 이전 블록 정보의 유입 경로 (코드 세부와 라인 번호: pdfs/BD_ARCHITECTURE_K0.pdf)

A. 캔버스와 길이 스펙 (blk4 예시; `build_canvas`)



노랑 = 클린 조건 prefix (loss 제외); END tail은 dst 블록 내부에서 학습 대상; PAD 블록은 loss 제외.

B. 이전 블록 정보의 유입 = self-attention 단일 경로

	B1	B2	B3	B1'	B2'	B3'
B1	BD	.	.	.	.	.
B2	.	BD	.	OBC	.	.
B3	.	.	BD	OBC	OBC	.
B1'	.	.	.	BD	.	.
B2'	.	.	.	BC	BD	.
B3'	.	.	.	BC	BC	BD


	B1	B2	B3*
B1	✓	.	.
B2	✓	✓	.
B3*	✓	✓	✓


왼쪽 (학습, `get_block_diff_mask`) : $[x_t(B1-B3) \parallel x_0(B1'-B3')]$ 입력에서 노이즈 블록 B3의 쿼리는 자기 블록(BD)과 이전 블록들의 클린 x_0 (OBC — 이전 블록 정보의 유일한 학습 토크)만 본다. BC는 클린 절반의 표현 유지용.

오른쪽 (샘플링, `get_block_causal_mask`) : 현재 블록 B3*의 모든 토큰이 커밋된 B1, B2를 매 레이어에서 직접 attend (주황 강조). 커밋 토큰은 동결($t=0$)이며 KV 캐시 없이 매 forward 재인코딩.

adaLN 조건 경로($c = t + \text{OD 임베딩}$)는 이전 블록의 내용을 나르지 않는다 — 내용은 100% attention으로 흐른다.

C. BDTransformer 타워 — 아래에서 위로 읽기: 조건과 이전 블록 내용의 정확한 주입 지점





adaLN MLP (Mish→Linear, zero-init)

→ $(\gamma_1, \beta_1, \alpha_1, \gamma_2, \beta_2, \alpha_2)$

adaLN이 매 블록의 $\gamma/\beta/\alpha$ 박스 전부에 공급

↘ 주황 박스 전부

- γ, β, α 는 모델 파라미터가 아니다. 학습 파라미터는 보라색 adaLN MLP의 가중치(zero-init → 초기엔 전 블록 항등)이고, $\gamma/\beta/\alpha$ 는 그 MLP가 토큰·샘플마다 c에서 계산하는 활성화값이다. 조건은 가중치를 바꾸지 않고 정규화된 활성화값을 feature별 $\text{scale}(1+\gamma)/\text{shift}(\beta)$ 하고 서브레이어 출력을 $\text{gate}(\alpha)$ 한다 — LN이 affine-free인 이유.
- 이전 블록의 내용은 adaLN이 아니라 attention의 K/V로 들어온다 (파란 박스). 요약: 내용은 K/V로, 조건(블록별 t-OD)은 $\gamma\beta\alpha$ 로.

$(\gamma_1, \beta_1, \alpha_1, \gamma_2, \beta_2, \alpha_2) = \text{adaLN_MLP}(c).\text{chunk}(6)$ # BDBlock.forward, bd_models.py:149–153

$x = x + \alpha_1 \odot \text{Attn}((1+\gamma_1)\odot \text{LN}(x) + \beta_1, \text{attn_mask})$

$x = x + \alpha_2 \odot \text{MLP}((1+\gamma_2)\odot \text{LN}(x) + \beta_2)$

D. Open-ended semi-AR 생성: 블록 append → first-hitting으로 토큰 1개씩 공개(공개 토큰은 즉시 다음 forward의 문맥) → 커밋 블록 스캔: dst → hit(정지) / END → miss(정지) / 아니면 다음 노이즈 블록 append.

학습의 OBC(노이즈→클린 과거)와 샘플링의 커밋-참조가 정확히 대응하도록 설계되어 (teacher forcing), 학습·생성의 조건화 분포가 일치한다. blk1에서는 모든 정보가 커밋-참조로만 흘러 causal LM이 되고, blk64(=MDLM)에서는 OBC가 공집합이 된다 — block size가 두 통로의 비율을 보간한다 (§6.9).

1. Block size sweep (v2) — mask vs graph(d=2.0), 진짜 held-out, 시드 3개 mean±std

v2 프로토콜: 14개 모델 전부 재학습 (시드된 데이터 순서 shuffle=False + seed 1 → train/test 멤버십 완전 재현), 평가는 학습에 쓰이지 않은 20% test split에서만 시드 고정으로 추출한 공유 1,000쌍(모든 모델 동일), 모델당 생성 시드 3개. 통제 변인: 평가셋·데이터 분리·생성 난수 모두 통제됨. v1 체크포인트는 sets_model/v1_archive/에 보존 (§4-§7의 진단·guidance 결과는 v1 산출물이며, except_0 평가라 본 split 문제와 무관하게 유효).

1.1 mask 커널 (absorbing)

block size	hit (=arrival)	valid	valid^hit (raw)	EM	PC	DTW	len err	len corr	s/path
1	0.997±.002	0.934±.007	0.934±.007	0.830±.011	0.869±.010	0.032±.002	0.84	+0.864	0.034
2	0.958±.007	0.842±.006	0.822±.006	0.769±.005	0.799±.005	0.038±.004	0.45	+0.982	0.030
4	0.958±.001	0.836±.004	0.811±.004	0.747±.010	0.783±.008	0.037±.003	0.37	+0.991	0.030
8	0.951±.002	0.808±.006	0.774±.006	0.716±.008	0.754±.007	0.042±.002	0.40	+0.993	0.030
16	0.898±.006	0.680±.006	0.625±.002	0.607±.009	0.637±.008	0.061±.003	0.56	+0.989	0.030
32	0.858±.010	0.474±.004	0.420±.002	0.413±.002	0.437±.002	0.081±.003	0.96	+0.968	0.031
64	0.839±.005	0.430±.014	0.373±.010	0.366±.012	0.391±.012	0.072±.004	0.89	+0.988	0.033

1.2 graph 커널 (uniform-state CTMC, d = 2.0)

block size	hit (=arrival)	valid	valid^hit (raw)	EM	PC	DTW	len err	len corr	s/path
1	0.429±.001	1.000±.000	0.429±.001	0.093±.006	0.168±.007	0.437±.022	36.4	+0.237	0.94
2	0.173±.014	0.997±.001	0.173±.014	0.399±.008	0.558±.005	0.488±.010	6.48	+0.492	0.42
4	0.128±.007	0.978±.002	0.128±.007	0.309±.012	0.499±.008	0.302±.003	4.50	+0.719	0.10
8	0.058±.004	0.991±.001	0.058±.004	0.124±.012	0.331±.006	0.282±.001	4.53	+0.783	0.07
16	0.029±.002	0.996±.002	0.029±.002	0.148±.008	0.390±.006	0.377±.005	5.66	+0.705	0.05
32	0.035±.002	0.969±.002	0.035±.002	0.174±.002	0.411±.004	0.394±.002	5.96	+0.693	0.05
64	0.027±.004	0.966±.003	0.027±.004	0.198±.006	0.430±.001	0.363±.008	5.74	+0.724	0.04

2. 실제 경로 길이 구간별 arrival (v2)

mask

block size	len 2-15	len 16-25	len 26-35	len 36+
1	0.996	0.996	0.996	1.000
2	0.931	0.962	0.965	0.980
4	0.912	0.967	0.974	0.987
8	0.910	0.972	0.951	0.972
16	0.834	0.927	0.904	0.927
32	0.846	0.852	0.864	0.886
64	0.795	0.847	0.855	0.864

graph (d=2.0)

block size	len 2-15	len 16-25	len 26-35	len 36+
1	0.502	0.444	0.387	0.336
2	0.202	0.163	0.177	0.134
4	0.139	0.134	0.124	0.098
8	0.050	0.058	0.056	0.076
16	0.046	0.031	0.022	0.008
32	0.038	0.025	0.029	0.071
64	0.026	0.037	0.015	0.028

3. 발견 (v2)

- Held-out 검증: 암기 인플레이션 없음. 진짜 held-out의 v2 수치가 v1의 (train 중첩 가능) 수치와 노이즈 이내로 일치한다 — blk1: 0.997/0.934 vs 0.997/0.943; blk4: 0.958/0.811 vs 0.943/0.821. §1의 결론은 데이터 누수의 산물이 아니었다.

- **mask: 작은 블록이 이기고 blk1이 전면 우승** (hit 0.997, valid $\wedge$ hit 0.934). blk2-8은 고원(0.77-0.82; v2에서는 blk2가 근소 우위), blk16부터 절벽 (0.625 $\rightarrow$ 0.373). hit은 완만히($\sim$ 16%p), validity는 급하게($\sim$ 50%p) 떨어진다 — §4.3의 무작위 공개 순서 메커니즘 그대로.
- **graph(d=2.0)는 정확히 거울상이다.** 인접행렬 제약 디코드 덕에 **validity는 전 블록에서 0.97-1.00**이지만 arrival이 block size와 함께 붕괴한다 (0.429 $\rightarrow$ 0.027). 최고 graph 셀은 blk1(0.429) — 그래도 mask blk1(0.997)의 절반 이하이고, 경로가 배회한다 (len err 36.4, len corr 0.24, 0.94 s/path). graph blk4의 0.128은 이전 보고서의 0.099와 정합.
- **horizon 특성도 커널별로 같린다:** mask는 blk1-16에서 길이에 따른 arrival 감쇠가 없고(§2 좌), graph는 모든 블록에서 길이에 따라 감쇠한다(§2 우) — 제약된 결음은 멀수록 목적지에 닿기 어렵다.
- **길이 보정:** mask는 blk $\geq$ 2에서 len corr $\geq$ +0.97 (dst-절단 기하, §4.1); graph는 0.24-0.78로 불량.
- **종합 판정은 §6.9와 동일:** mask = 결단력 있지만 거침(후처리로 수리 가능), graph = 합법이지만 길을 잃음(수리 불가능한 유형). block size의 비용이 mask에서는 validity로, graph에서는 arrival로 지불된다.

4. 실패 해부 — 길이 보정의 출처, miss의 정체, validity가 떨어지는 이유

이 절의 측정은 저장된 체크포인트에 새로 400쌍을 추출해 돌린 사후 진단 (refine 없음); n_miss = 21-49라 하위집단 비율에는 $\sim$ 10%p 표집 노이즈.

4.1 높은 len corr는 대부분 dst-절단 기하학이지 END 예측이 아니다

생성 길이는 hit 경로에선 **dst 토큰이 방출되는 위치**(경로가 dst에서 절단됨)로, miss 경로($\sim$ 5-12%)에서만 **END 방출 위치**로 결정된다. 하위집단별 분해:

block size	hit	len corr (전체)	len corr (hit만)	len corr (miss만)	hit 우회율 gen/real
64	0.877	0.985	0.991	0.952	1.011
16	0.927	0.988	0.988	0.970	1.011
4	0.963	0.980	0.990	0.778	1.012

hit 경로는 실제(최단) 경로 대비 $\sim$ 1.1%만 우회하며 dst에 도달하므로 길이는 OD쌍의 그래프 거리에 고정 — corr 0.99는 기하학의 귀결. 이것이 blk64에서 validity가 무너져도 len corr가 0.99로 유지되는 이유: 큰 블록이 깨는 것은 국소 edge 일관성이지 "dst까지 몇 토큰"의 전역 구조가 아니다. END 보정은 실재하지만 부차적: miss 만 관찰하며 거기서도 양호(대형 블록에서 miss-only corr 0.95-0.97, 평균 길이 일치) — END가 없었다면 miss가 캔버스 한계까지 폭주해 전체 corr를 끌어내렸을 것.

4.2 miss는 near-miss다: 모델은 목적지 문 앞까지 간다

miss = dst 정점을 한 번도 밟지 않은 채 END(종료 선언)를 방출한 경우: 본 raw 보고서에선 후처리가 없어 arrival 실패로 집계된다. miss 경로의 마지막 정점에서 dst까지의 그래프 hop 거리:

block size	n_miss	중앙값 hops	평균	$\leq$ 1 hop	$\leq$ 2 hops	$\leq$ 5 hops
64	40	1	1.8	52%	92%	98%
16	39	2	3.3	33%	87%	95%
4	21	1	2.8	52%	81%	90%

hit율과 합치면 blk64에서도 전체 경로의 $\sim$ 99%가 dst 2 hop 이내에서 종료. miss는 내비게이션 실패가 아니라 마지막 순간의 토큰 식별 실패("정확한 dst id 대신 END 방출") — dst 직후 END를 학습시키는 길이 스펙의 예측 가능한 부작용이기도 하다. 이전 보고서에서 refine_es(dst 인접 정점에서 절단 + dst 부착)가 arrival을 +3%p 회복할 수 있었던 이유와 정확히 맞물린다.

4.3 대형 블록에서 validity가 떨어지는 이유: 최소한 국소 스킵의 경로 단위 증폭

	blk64	blk16
invalid edge (edge 단위)	3.6% (332 / 9,130)	2.2% (199 / 9,150)
invalid edge $\geq$ 1개 포함 경로	52%	33%
해당 경로당 invalid edge 수	1.6	1.5
invalid 쌍의 실제 hop 거리	중앙값 3; 91% $\leq$ 3	중앙값 3; 87% $\leq$ 3
발생 위치	블록 내부 332, 블록 경계 0	내부 188, 경계 11

- **붕괴가 아니라 증폭.** blk64의 edge 단위 정확도는 여전히 96.4%; 경로당 $\sim$ 23 edge이므로 P(전부 유효) $\approx$ 0.964²³ $\approx$ 0.43 — 관측치 0.50과 일치. all-or-nothing 경로 지표가 3.6%의 edge 오류를 50%의 경로 실패로 보이게 한다.
- **오류는 전부 블록 내부.** 블록 경계 edge(이전 블록 완전 커밋 후 생성 = 사실상 AR)는 invalid 0건. 원인은 first-hitting의 블록 내 무작위/공개 순서: 비인접 앵커 사이의 양방향 제약 조건부는 좌 $\rightarrow$ 우 조건부보다 조합적으로 어렵고 덜 정확하게 학습되며, 블록이 클수록 그런 패턴이 많아진다.
- **스킵은 국소적.** invalid 쌍의 실거리는 2-3 hop(중앙값 3): 다리 정점 하나를 빠뜨리는 것이지 순간이동이 아니다.

4.4 시사점 — 개선 방향

- **대형 블록에서도 모델은 망가지지 않았다:** 전역 구조(중점 배치·길이·근최단 경로)는 온전; 결합은 희소(3.6%)·국소(2-3 hop)·정확히 위치 지정 가능(인접성 검사). 이 실패 프로파일은 **재학습보다 후처리에 유리하다**.
- **Local splice (P1, §5에서 구현):** invalid (u, v)마다 최단경로 삽입(중앙값 정점 2개). 구조상 validity → 1.0, 중점 불변으로 hit 유지.
- **학습 쪽 수정은 2차적:** 용량/epoch/clipped schedule로 edge 오류율은 낮출 수 있으나 any-order infilling은 본질적으로 AR보다 어렵다(원 논문의 블록-우도 경향).
- **샘플러 쪽 수정은 분포를 바꾼다:** 블록 내 좌→우 공개나 인접행렬 제약 디코드는 균등 선택 first-hitting과 학습된 역과정의 등가성을 깨는 별도 디코더 — 학습된 모델의 조건부는 순서-일관적이지 않고, 좌→우가 의존하는 prefix 조건부 패턴은 대형 블록의 무작위 마스킹 학습에서 드물다. 경험적 검증 필요.

4.5 노트 (미실행): END-tail의 loss 비중은 block size에 선형으로 커진다 — loss engineering 레버

프로젝트 길이 스펙에서 dst 블록 tail의 END 토큰은 각각 독립적인 학습 대상이다 (build_canvas : tail이 loss_mask 안). tail 길이는 블록 나머지에 균등하므로 기대 크기는 (B-1)/2 — 감독 집합의 구성이 block size에 따라 이동한다 (평균 경로 ≈ 24):

block size	loss 내 경로 토큰	END 토큰 (평균)	감독에서 END 비중
4	≈23	≈1.5	≈6%
16	≈23	≈7.5	≈25%
64 (= MDLM)	≈23	≈31.5	≈58%

- **동전의 양면.** 공로: 풍부한 END 감독이 §4.1-4.2에서 측정된 탁월한 END 보정(miss-only len corr 0.95+, 그럴듯한 길이에서의 종료)의 원천이다. 의심되는 비용: END는 쉬운 표적(dst 뒤는 문맥이 완전 결정)이라 큰 B에서는 gradient의 다수가 쉬운 토큰으로 가서 경로 토큰의 감독이 희석된다 — §1의 block size에 따른 validity 감쇠의 부분적 후보 설명. **미검증 가설**이며, block size 효과에는 §4.3의 무작위 공개 순서라는 독립 메커니즘도 있으므로 귀속에는 전용 ablation이 필요하다.
- **가능한 수정 (engineering, 모두 미실행):** (i) 상수-질량 END 재가중 — tail의 토큰당 가중치를 c/(tail 길이)로 스케일해 END loss 비중을 block-size 불변으로 (c ≈ 토큰 1-2개 몫); (ii) 첫 END만 감독 — 첫 END는 전체 가중치, 나머지는 PAD처럼 제외 (“EOS loss 1개” 해석); (iii) 감쇠 tail — tail 내부 기하급수 다운웨이트. 셋 다 ~1/t MDLM 가중과 그대로 합성된다.
- **검증 시 주의:** 다운웨이트는 §4.2가 공로로 꼽은 END 보정(miss 길이, 문 앞 정지)을 훼손할 수 있으므로 validity와 miss-END 보정을 반드시 함께 평가할 것; 또한 어떤 변경이든 본 보고서의 전 런과의 비교 가능성을 깨므로, 비중이 가장 큰(25-58%) blk16/64에서 먼저 시험할 것.

5. 후처리 결과 — P1 (local splice), P3 (endpoint patch), P1+P3

§4.4의 구현(eval_bd_postproc.py): 체크포인트마다 1,000쌍을 한 번 생성(raw)한 뒤 같은 생성물에 세 후처리를 적용해 채점. **P1:** invalid (u, v)마다 최단경로 u→v 삽입; **P3**(= refine_nx): miss 중점에서 dst까지 graft; **P1+P3:** 둘의 결합. 새로 추출한 평가셋(seed 1)이라 raw 값은 §1과 ±1%p 이내에서 다름.

blk	변형	arrival	valid	valid^hit (raw)	EM	PC	DTW	len err	patch len
1	raw	0.998	0.935	0.935	0.836	0.874	0.036	0.64	—
	P1	0.998	1.000	0.998	0.854	0.902	0.035	0.94	0.42
	P3	1.000	0.935	0.935	0.836	0.874	0.035	0.68	0.04
	P1+P3	1.000	1.000	0.998	0.854	0.902	0.034	0.99	0.46
2	raw	0.937	0.797	0.761	0.735	0.761	0.053	0.62	—
	P1	0.937	0.999	0.937	0.783	0.846	0.052	1.80	1.71
	P3	1.000	0.797	0.761	0.724	0.753	0.051	0.68	0.21
	P1+P3	1.000	1.000	0.937	0.773	0.837	0.050	1.95	1.92
4	raw	0.958	0.822	0.794	0.737	0.773	0.040	0.46	—
	P1	0.958	1.000	0.958	0.772	0.847	0.044	1.19	0.96
	P3	1.000	0.822	0.794	0.729	0.768	0.042	0.59	0.19
	P1+P3	1.000	1.000	0.958	0.764	0.841	0.043	1.33	1.14
8	raw	0.960	0.790	0.768	0.704	0.739	0.040	0.42	—
	P1	0.960	1.000	0.960	0.764	0.845	0.045	1.13	1.05
	P3	1.000	0.790	0.768	0.698	0.735	0.039	0.49	0.15
	P1+P3	1.000	1.000	0.960	0.757	0.838	0.044	1.23	1.20

16	raw	0.885	0.626	0.569	0.541	0.575	0.072	0.63	—
	P1	0.885	1.000	0.885	0.612	0.727	0.076	2.35	2.24
	P3	1.000	0.626	0.569	0.523	0.562	0.068	0.79	0.36
	P1+P3	1.000	1.000	0.885	0.588	0.708	0.072	2.58	2.59
32	raw	0.885	0.522	0.474	0.450	0.478	0.061	0.77	—
	P1	0.885	1.000	0.885	0.582	0.705	0.062	1.96	1.80
	P3	1.000	0.522	0.474	0.432	0.466	0.059	0.85	0.26
	P1+P3	1.000	1.000	0.885	0.558	0.686	0.060	2.14	2.06
64	raw	0.886	0.517	0.465	0.423	0.458	0.055	0.81	—
	P1	0.886	1.000	0.886	0.588	0.711	0.058	1.85	1.75
	P3	1.000	0.517	0.465	0.411	0.450	0.054	0.90	0.27
	P1+P3	1.000	1.000	0.886	0.569	0.695	0.056	2.01	2.01

block size마다 같은 생성물의 네 변형 (파일: `sets_res/BD_mask_blk*_postproc.res`). 열 정의: hit는 항상 후처리 전 출력에서 측정되므로 $\text{valid} \wedge \text{hit}$ (raw)는 후처리로 부풀 수 없다 — P1+P3(valid = arrival = 1.0 구조 보장)에서는 남은 유일한 모델 의존량인 raw hit rate와 같다. blk2의 P1 valid 0.999는 연결 경로가 없는 invalid 쌍 1건을 그대로 둔 것.

- §4.4의 예측이 거의 정확히 실현: blk64에서 $\text{valid} \wedge \text{hit}$ 0.465 → 0.886 (= hit), 평균 패치 비용 1.75토큰; 수선 불가 쌍은 전 런에서 0건.
- P1은 대형 블록에서 EM/PC도 개선 (blk64 EM 0.423 → 0.588, PC 0.458 → 0.711): 삽입된 다리가 실제 경로 조각이라 참조 경로와 겹침 — 패치가 경로를 합법화 할 뿐 아니라 실제 경로 쪽으로 이동시킨다.
- P1+P3는 모든 block size에서 $\text{valid} = 1 \wedge \text{arrival} = 1$ 의 구조적 보장을 제공하며 DTW는 거의 불변, len err는 +0.3-2.0토큰. 이 후처리 하에서 사용 가능 경로 비율 = raw hit rate — 후처리가 대형 블록의 validity 비용을 전부 흡수하고, 남은 block size 페널티는 hit뿐.

6. 예외 상황(except_0)에서의 importance-weight guidance

설계·유도 전문: `pdfs/BD_GUIDANCE_FORMULATION.pdf`. 부분 경로 discriminator(edge-existence 채널 + 시나리오 인접행렬 GraphSAGE, bounded logit, label smoothing)가 매 first-hitting reveal에서 mean-field 후보 $N = 100$ 개를 $w = D/(1-D)$ 로 재가중. 백본은 §1의 normal 학습 체크포인트($v_4\text{-normal} \equiv v_3\text{-normal}$); 평가 = 예약된 except_0 OD쌍 1,000개, 예외 인접행렬 기준 채점, raw. `rem-path` = 제거된 edge를 1개 이상 쓴 경로 비율; ESS = importance weight의 유효 표본 수 (reveal당 평균: $N = 100$).

6.1 주축 — block size × guidance (fam 0.05, 데이터 1%, 실험 1)

blk	변형	arrival	valid (exc)	$\text{valid} \wedge \text{hit}$ (raw)	rem-path	EM	PC	ESS/100
4	base	0.939	0.253	0.239	0.661	0.231	0.240	—
	guided (data)	0.948	0.306	0.284	0.651	0.269	0.285	99.1
	guided (mix)	0.948	0.315	0.290	0.651	0.281	0.296	99.1
8	base	0.944	0.242	0.229	0.656	0.211	0.223	—
	guided (data)	0.937	0.286	0.268	0.648	0.266	0.275	98.8
	guided (mix)	0.936	0.293	0.271	0.646	0.272	0.281	98.8
16	base	0.896	0.206	0.181	0.642	0.177	0.188	—
	guided (data)	0.885	0.245	0.208	0.625	0.213	0.225	97.9
	guided (mix)	0.884	0.250	0.215	0.630	0.214	0.228	98.0
32	base	0.897	0.165	0.153	0.657	0.136	0.147	—
	guided (data)	0.885	0.199	0.172	0.649	0.156	0.173	97.4
	guided (mix)	0.878	0.205	0.169	0.649	0.165	0.181	97.8
64	base	0.864	0.164	0.151	0.634	0.131	0.145	—
	guided (data)	0.876	0.205	0.181	0.630	0.157	0.176	94.1
	guided (mix)	0.882	0.204	0.183	0.635	0.157	0.175	95.5

6.2 Pivot (blk 4 / 16)

축	구성	blk4 valid (base→guided)	blk16 valid (base→guided)	해석
더 어려운 시나리오	fam 0.1, 1%, 실험 1 (mix)	0.096 → 0.120	0.057 → 0.088	2배 어려운 그래프(rem-path 0.86)에서도 같은 상대 개선
데이터 양	fam 0.05, 3%, 실험 1 (mix)	0.253 → 0.311	0.206 → 0.253	1%와 사실상 동일 — 데이터 양은 병목이 아님
unseen 시나리오 (실험 2)	disc는 except 1-99로 학습, 평가는 except_0 (data)	0.253 → 0.314	0.206 → 0.256	except_0 전용 disc와 동등 이상 (0.306 / 0.245): 인접행렬 직접 참조 discriminator(edge-existence 조회 + GraphSAGE)가 한 번도 본 적 없는 시나리오로 전이 — 실험 2.1의 일반화 가설 지지

6.3 Proposal 온도 (동반 문서 §6 처방 (i); fam 0.05, 1%, data disc)

blk	τ	arrival	valid	rem-path	ESS/100
4	1.0	0.948	0.306	0.651	99.1
	1.5	0.910	0.285	0.639	98.3
	2.0	0.853	0.236	0.615	97.1
16	1.0	0.885	0.245	0.625	97.9
	1.5	0.834	0.218	0.602	97.1
	2.0	0.729	0.147	0.586	97.0

6.4 발견

- **Absorbing 커널 instantiation은 기계적으로 작동한다.** 이전에 관측된 weight 분산 폭발이 재발하지 않음(bounded logit + label smoothing + negative 커버리지); 부분 경로에 대한 disc 검증 정확도 0.71-0.88; 모든 block size에서 **일관되게** validity +4-5%p, EM/PC +3-5%p, arrival 불변.
- **그러나 효과는 작고, 원인이 이제 추측이 아니라 측정이다:** ESS $\approx$ 94-99 / 100. mean-field 후보 100개가 near-clone이라 가중치가 거의 평평 — MASKED_GUIDANCE.pdf §6이 예측한 proposal entropy 병목이 BD의 모든 block size에서 실측됨. 제거 edge 사용률이 거의 불변(0.66 → 0.65)인 것이 그 증거: 재가중은 제시된 후보 중에서만 고를 수 있는데, 제거 edge를 피하는 후보가 거의 제시되지 않는다.
- **unseen 시나리오 일반화(실험 2)가 가장 명확한 긍정 결과:** except_0을 본 적 없는 disc가 전용 disc와 동등(약간 우위)하게 guidance한다. 시나리오 정보는 암기된 경로가 아니라 인접행렬 조회 피처를 통해 들어간다.
- **Proposal 온도를 올리는 것은 얻는 것보다 잃는 것이 크다:** rem-path -2~-6%p에 arrival -4~-17%p; ESS는 여전히 $\approx$ 97. 같은 proposal을 평평하게 만드는 것으로는 부족하다.
- **시사점.** 재가중 기계는 검증됐고, 병목은 proposal이다. 자연스러운 다음 단계는 discriminator를 유지한 채 후보 생성기를 바꾸는 것: (i) A_{scn} 하의 adjacency-masked proposal (동반 문서 처방 (ii)) — 제거 edge를 아예 쓸 수 없는 후보들 위에서 IW guidance가 합법적 우회로를 선택; 그리고/또는 (ii) 시나리오 그래프 기준의 P1형 splice와 discriminator의 채점 측 활용.

6.5 Adjacency-masked proposal (Lemma 3) — 병목 해소의 실측

§6.1과 같은 프로토콜에, 후보 proposal을 공개된 이웃 기준 시나리오-합법 전이로 마스킹 (BD_GUIDANCE_FORMULATION.pdf §6: 이상적 discriminator 하에서 정확 — 제외되는 후보는 target 가중치가 0). `adj-only` = discriminator 없이 마스킹만 (제약 자체의 효과 분리용 컨트롤).

blk	변형	arrival	valid (exc)	valid $\wedge$ hit (raw)	rem-path	rem-edge	EM	PC
4	base	0.939	0.253	0.239	0.661	0.051	0.231	0.240
	guided (§6.1)	0.948	0.315	0.290	0.651	0.050	0.281	0.296
	adj-only	0.873	0.316	0.270	0.502	0.030	0.275	0.291
	adj+guided	0.868	0.368	0.316	0.495	0.030	0.316	0.337
8	base	0.944	0.242	0.229	0.656	0.050	0.211	0.223
	guided	0.936	0.293	0.271	0.646	0.050	0.272	0.281
	adj-only	0.863	0.296	0.257	0.489	0.031	0.250	0.267
	adj+guided	0.868	0.338	0.292	0.487	0.031	0.300	0.315
16	base	0.896	0.206	0.181	0.642	0.049	0.177	0.188
	guided	0.884	0.250	0.215	0.630	0.048	0.214	0.228
	adj-only	0.822	0.264	0.208	0.486	0.031	0.212	0.232

	adj+guided	0.809	0.295	0.230	0.467	0.030	0.246	0.265
32	base	0.897	0.165	0.153	0.657	0.050	0.136	0.147
	guided	0.878	0.205	0.169	0.649	0.050	0.165	0.181
	adj-only	0.832	0.212	0.172	0.486	0.031	0.161	0.181
	adj+guided	0.817	0.238	0.183	0.504	0.033	0.180	0.202
64	base	0.864	0.164	0.151	0.634	0.048	0.131	0.145
	guided	0.882	0.204	0.183	0.635	0.048	0.157	0.175
	adj-only	0.805	0.204	0.168	0.488	0.031	0.153	0.173
	adj+guided	0.818	0.243	0.193	0.480	0.030	0.179	0.205

Pivot: fam 0.1 adj+guided — blk4 valid 0.096 → 0.165, rem-path 0.868 → 0.716 (arrival 0.95 → 0.80); blk16 valid 0.057 → 0.126. 실험 2 disc + adj proposal: blk4 valid 0.366, blk16 0.295 — except_0 전용 disc(0.368 / 0.295)와 구분 불가: proposal을 바꿔도 일반화가 유지됨.

- **병목은 정말 proposal이었다.** 마스크만으로(adj-only) 제거 edge의 *edge 단위* 비율이 절반(0.050 → 0.030), rem-path가 0.66 → ~0.49 — 재가중이 이루지 못한 폭. 결합(adj+guided) 시 baseline 대비 validity 총 +9-12%p (blk4: 0.253 → 0.368, 상대 +45%), EM 상대 +37%.
- **이론이 예측한 그대로의 분업:** 제거 edge 회피는 마스크링(proposal)이 담당 — discriminator는 rem-path를 더 줄이지 못함(~0.49 유지) — 재가중은 합법 후보들 위에서 경로 품질을 추가(모든 블록에서 adj-only 대비 valid +4-5%p, EM +0.03-0.04). Lemma 3의 "마스크링은 가중치 0인 후보를 삭제하고, D는 생존자를 순위 매긴다"가 데이터에 그대로 보인다.
- **비용은 arrival (~4~9%p):** 불법 지름길이 막힌 모델이 때로 방향하다 miss로 끝난다. §5의 P3 endpoint patch(예외 그래프 기준)가 구조적으로 arrival = 1.0을 복원하므로, **adj+guided + A_{scn} 기준 P1/P3가 자연스러운 완성형** — 다음 단계로 남김.
- **잔여 rem-path ≈ 0.49는 Z ≈ 0 폴백에서 발생** (상호 불법인 masked 앵커가 unmasked reveal을 강제 — Lemma 3의 후보-내부 caveat) — 남은 누수는 국소적 이고 원인이 특정됨.
- **ESS는 여전히 ≈ 95-99:** 합법 후보들끼리도 near-clone. discriminator의 기여는 경로당 ~24회 reveal에 걸쳐 누적되는 작지만 체계적인 미세 조정이며, 추가 여지는 discriminator가 아니라 **합법 우회로들 사이의 diversity**(repaint식 재마스크, 혼합 proposal)에 있다.

6.6 Guided 경로의 해부와 예외 그래프 기준 후처리

사후 진단: 새 평가 400쌍, adj+guided (mix disc, N = 100); bad edge를 두 그래프 기준으로 분류; P1/P3는 예외 그래프 G_{exc} 기준으로 계산.

	blk4	blk16
bad edge (edge 단위)	4.8% (421 / 8,826)	5.9% (514 / 8,661)
— removed (normal엔 있었으나 시나리오에서 폐쇄)	2.9%	3.0%
— alien (normal 그래프에도 없던 edge)	1.9%	2.9%
bad edge ≥1개 포함 경로	62%	71%
removed 쌍의 G _{exc} 실제 우회 거리	중앙값 4 hop (≤3은 21%, 최대 15)	중앙값 4
alien 쌍의 G _{exc} 실제 거리	중앙값 5 (최대 44)	중앙값 3 (최대 45)

- **최소하지만 normal 해부(\$4.3)보다 사거리가 길다.** normal에서는 모든 bad edge가 2-3 hop 국소 스킵(중앙값 3, 91%가 ≤3)이었는데 여기서는 중앙값 4-5. 구조적 이유: removed edge를 밟았다는 건 원래 길이 있었다는 뜻이고, 폐쇄 주변의 진짜 우회로는 본질적으로 길다. alien 잔여(~2-3%)는 Z ≈ 0 폴백으로 새는 것이며 최대 44-45 hop짜리 장거리 순간이동도 소수 포함.
- **모든 bad 쌍이 수선 가능:** P1(G_{exc} 최단경로 브리지) + P3(G_{exc} 종점 패치)가 400 × 2 경로 전부에서 성공 — 수선 불가 0건.

blk	변형	arrival	valid (exc)	EM	PC	평균 패치	수선 불가
4	adj+guided raw	0.868	0.368	0.316	0.337	—	—
	+ P1+P3 (G _{exc})	1.000	1.000	0.325	0.475	5.3 토큰	0
16	adj+guided raw	0.809	0.295	0.246	0.265	—	—
	+ P1+P3 (G _{exc})	1.000	1.000	0.268	0.426	6.2 토큰	0

- **PC 급상승 (+0.14-0.16):** 삽입된 G_{exc} 최단 브리지가 실제 우회 경로와 겹침 — 패치가 단순 합법화가 아니라 경로를 정답 쪽으로 이동시킨다. 패치 비용(~5-6토큰, 경로의 ~25%)이 normal 때(+1-2)보다 큰 것은 진짜 우회로가 본질적으로 길기 때문.
- **전체 시스템 관점 (blk4):** baseline raw EM 0.231 → adj+guided + P1+P3 EM 0.325 (상대 +41%), 여기에 valid = 1 ∧ arrival = 1의 구조적 보장 — 예외 상황 대응 파이프라인의 완성형 후보. (400쌍 진단 기준; 전 block size × 1,000쌍 본 실험이 자연스러운 확정 단계.)

6.7 Negative class의 완결: 순수 모델 분포 discriminator

Eq. (2)의 분모는 "normal 데이터"가 아니라 p_θ — 기준 `data / mix` negative는 $p_\theta \approx q_{\text{normal}}$ 가정을 낀 근사였다. 이번 라운드가 그 간극을 닫는다: block size마다 해당 체크포인트의 **unconditional 생성** 20k개(조건 dropout이 ori+dst를 *동시*에 null로 학습하므로 plan(None, None)이 in-distribution)를 negative의 100%로 사용해, 블록별 이론-충실 discriminator를 만들었다 (`BDdisc*_model_blk{B}`). disc 입력은 캔버스 형식([dst = 경로 자신의 종점, path...])을 유지해 형식 차이로 컨닝하지 못하게 했다; 잔여 근사는 unconditional $p_\theta(x)$ 가 OD-조건부 $p_\theta(x | od)$ 가 아닌 주변분포라는 점.

blk	valid: base	neg = data	neg = mix	neg = model	adj+mix	adj+model
4	0.253	0.306	0.315	0.321	0.368	0.371
8	0.242	0.286	0.293	0.297	0.338	0.343
16	0.206	0.245	0.250	0.267	0.295	0.307
32	0.165	0.199	0.205	0.222	0.238	0.253
64	0.164	0.205	0.204	0.221	0.243	0.248

valid (exc) 기준; EM/PC도 같은 순서 (예: blk32 EM 0.156 → 0.165 → 0.177 plain; adj 0.180 → 0.192). arrival, rem-path, ESS는 negative class와 무관 — discriminator는 proposal이 내놓는 것을 바꿀 수 없고 순위만 매길 수 있다.

- **이론적 순서가 단조롭게 실현됨**: 모든 block size에서, plain+adj+guided 모두 $\text{data} < \text{mix} < \text{model}$ (10/10 비교). negative class가 진짜 분포 p_θ 에 가까울수록 guidance가 좋아진다.
- **이득은 블록이 클수록 커진다** (blk4는 mix 대비 +0.6%p, blk32/64는 +1.7%p): 큰 블록일수록 모델 분포가 normal 데이터에서 더 멀어지므로 (§1의 validity 감쇠) $p_\theta \approx q_{\text{normal}}$ 가정이 더 깨지고, 충실한 분모의 가치가 커진다.
- **현재까지 최고 수치** (adj + model-negative disc): blk4 valid 0.371 / EM 0.320 raw — baseline 0.253 / 0.231 대비 — 후처리 없이. §6.6의 P1+P3를 없으면 valid = arrival = 1.

6.8 3자 심층 분석: base / modelD / adj+modelD, 후처리 전후

평가 1,000쌍, blk 4/16, model-negative disc; inv-node = invalid edge에 접한 생성 정점의 비율; P1/P3는 G_{exc} 기준. 새 생성 시드라 raw 값은 §6.1/6.7 대비 통상 ±1%p 이내에서 다름. 전체 24행 (P1 단독 / P3 단독 포함)은 `sets_log/threeway.log`.

blk	구성	변형	arrival	valid	EM	PC	inv-edge	inv-node	rem-edge	patch
4	base	raw	0.963	0.242	0.222	0.230	6.44%	11.89%	5.07%	—
4	base	P1+P3	1.000	1.000	0.257	0.417	0%	0%	0%	6.3
4	modelD	raw	0.952	0.327	0.291	0.305	5.47%	10.19%	4.98%	—
4	modelD	P1+P3	1.000	1.000	0.306	0.461	0%	0%	0%	5.3
4	adj+modelD	raw	0.861	0.372	0.315	0.339	4.77%	8.71%	2.85%	—
4	adj+modelD	P1+P3	1.000	1.000	0.331	0.476	0%	0%	0%	5.3
16	base	raw	0.897	0.187	0.166	0.174	7.65%	13.92%	4.78%	—
16	base	P1+P3	1.000	1.000	0.204	0.375	0%	0%	0%	7.2
16	modelD	raw	0.895	0.252	0.217	0.230	7.12%	12.99%	4.77%	—
16	modelD	P1+P3	1.000	1.000	0.250	0.406	0%	0%	0%	7.2
16	adj+modelD	raw	0.822	0.288	0.241	0.258	5.87%	10.78%	2.95%	—
16	adj+modelD	P1+P3	1.000	1.000	0.283	0.435	0%	0%	0%	6.1

- **각 메커니즘이 invalid 구조를 깎는 지점 (raw 행)**. discriminator는 *alien* 성분(제거 아닌 invalid edge: blk4에서 1.37% → 0.49%)을 깎지만 removed edge(~5.0%)는 못 건드린다 — normal로 학습된 모델에게 그 edge는 완전히 정상으로 보이기 때문. 반면 adjacency 마스킹은 removed 성분을 절반으로(5.0% → 2.9%). 합치면 invalid-node 비율 11.9% → 8.7% (blk4), 13.9% → 10.8% (blk16).
- **후처리는 품질 순위를 평준화하지 않고 보존한다**: 모든 변형에서 EM·PC 기준 $\text{base} < \text{modelD} < \text{adj+modelD}$ (예: P1+P3 blk4 EM 0.257 < 0.306 < 0.331). 좋은 raw 경로가 좋은 최종 경로로 패치된다 — guidance와 후처리는 합성 가능하다.
- **정직한 기여 분배**: 후처리만으로도(base + P1+P3) valid = arrival = 1에 EM 0.204-0.257이 확보되고, guidance 스택은 그 위에 상대 EM +29-39% (blk4 0.257 → 0.331, blk16 0.204 → 0.283), PC +14-16%를 얻는다. PC의 엔진은 P1 (+0.15-0.19: G_{exc} 브리지가 실제 우회로와 겹침); P3는 거의 공짜 (0.1-0.8토큰).
- **잔여 사항**: blk16 adj+modelD에서 P1 단독은 valid 0.993 (G_{exc} 에서 연결 불가한 쌍 소수); P1+P3 조합은 1.000으로 마감.

6.9 MDLM vs. uniform-state diffusion (GDP): blk64 정면 비교

모든 경로가 한 64-블록에 들어가므로(데이터 최대 길이 59) blk64는 사실상 **full-canvas 영역**이다: mask 커널은 MDLM(고정 64-캔버스, END 패딩, PAD 블록 없음)이 되고, graph 커널 blk64 모델은 정확히 **GDP 논문의 uniform-state CTMC diffusion**(<end>-확장 상태공간, d = 2.0, 100-step reverse, 인접행렬 제약 디코딩)이다. 후자를 같은 normal 데이터로 학습(49.5분)하고 §6.8과 동일한 프로토콜을 적용했다; guided uniform 샘플러는 GDP 수식을 그대로 구현한다(매 reverse 스텝에서

MC-posterior의 $\hat{x}$ 를 D/(1-D) 가중 후보 평균으로 교체; adj 시 최종 제약 디코드가 A_{exc} 에서 동작). discriminator는 각 모델 자신의 unconditional pool에서 만든 model-negative.

커널	구성	변형	arrival	valid	EM	PC	inv-edge	rem-edge	patch	ESS
mask64 (MDLM)	base	raw	0.874	0.151	0.120	0.133	8.6%	4.9%	—	—
mask64	base	P1+P3	1.000	1.000	0.193	0.361	0%	0%	7.1	—
mask64	modelD	raw	0.888	0.222	0.173	0.192	8.4%	4.8%	—	94.9
mask64	modelD	P1+P3	1.000	1.000	0.220	0.379	0%	0%	7.6	—
mask64	adj+modelD	raw	0.806	0.251	0.183	0.211	6.8%	3.0%	—	95.1
mask64	adj+modelD	P1+P3	1.000	1.000	0.234	0.401	0%	0%	6.8	—
graph64 (uniform)	base	raw	0.043	0.460	0.080	0.200	5.1%	5.1%	—	—
graph64	base	P1+P3	1.000	1.000	0.051	0.233	0%	0%	11.9	—
graph64	modelD	raw	0.018	0.645	0.144	0.307	5.2%	5.2%	—	97.1
graph64	modelD	P1+P3	1.000	1.000	0.075	0.254	0%	0%	18.7	—
graph64	adj+modelD	raw	0.007	0.985	0.220	0.463	0.0%	0.0%	—	97.1
graph64	adj+modelD	P1+P3	1.000	1.000	0.105	0.307	0%	0%	18.9	—

- 두 커널은 정반대 방식으로 실패한다. MDLM/mask는 도착하지만(0.87) edge를 갠다(valid 0.15); uniform은 edge를 지키지만(valid 0.46, 내장 제약 디코드 덕에 alien edge 0 — 위반은 오직 removed edge뿐) 거의 도착하지 못한다(0.04, 이전 보고서의 graph 커널 프로파일 재현).
- guidance는 uniform 커널에서 훨씬 세계 듣는다 — 동반 문서 §6의 예측 확인: 재가중만으로 valid 0.460 → 0.645 (+18.5%p; mask는 +7.1%p), 시나리오-인접 행렬 디코드까지 결합하면 raw에서 valid 0.985, invalid edge 0.00% — 후처리 전에 validity 문제가 사실상 해결된다. 주목할 점: ESS는 두 커널 모두 ~97 — uniform의 우위는 가중치 다양성이 아니라 수정 가능성(revisability)이다. 100번의 재샘플링 스텝이 작은 넋지를 복리로 누적하는 반면, mask의 비가역 reveal은 넋지 한 번 뒤 결정을 잠근다.
- 그러나 guidance는 uniform의 arrival을 사주지 못한다 (0.043 → 0.007). 후처리가 경로당 ~19토권을 이식해야 하고(최종 경로의 절반이 패치), 합성 품질은 낮 게 남는다: EM 0.105 / PC 0.307 vs mask64의 0.234 / 0.401. P1+P3 보장 이후에도 end-to-end 승자는 mask 커널 — arrival은 모델이 공급해야 하는데, 그것 을 주는 쪽은 mask뿐이다.
- 방법론 관점의 독해: IW guidance가 빛나는 곳은 uniform 커널(크고 메커니즘이 깨끗한 개선), 과제가 풀리는 곳은 mask 커널이다. blk64 쌓이 설계 공간의 양 끝을 보여준다 — 수정 가능하지만 길을 잃는 쪽 vs 결단력 있지만 거친 쪽 — 그리고 §6.8의 완성형(small-block mask + adj + modelD + P1/P3)이 여전히 최적 운용점 이다.

uniform 커널의 경로가 실제로 끝나는 곳 (400쌍 진단, 미도달 경로의 종착점→dst G_{exc} hop 거리):

	arrival	중앙값 hops	평균	≤5 hops	생성 길이 (실제 24.1)	len corr
mask64 (참고, §4.2 프로파일)	0.87	1	~2	98%	~ 실제	0.99
graph64 base	0.040	5	8.6	53%	18.4	0.735
graph64 adj+modelD	0.005	17	19.1	12%	9.7	0.166

- 질적으로 다른 세 가지 실패. mask의 miss는 문 앞 토큰 식별 실수(중앙값 1 hop); 순수 uniform은 동네에서 길을 잃음(중앙값 5 hop, 길이 부족 18.4 vs 24.1); guided+제약 uniform은 중간에 포기 — dst에서 중앙값 17 hop, 실제 길이의 40%(9.7토권, len corr 0.17)에서 종료.
- 조기 종료의 메커니즘: 제약 디코드에서 모든 이동은 직전 정점의 이웃으로 마스킹되는데 <end> 상태는 항상 합법이다. $\hat{x}$ 의 질량이 이웃 아닌 정점들에 있을 때마 다 마스킹 후 <end>가 상대적으로 커져 걷기가 끝난다. 따라서 uniform의 대표 수치 valid = 0.985는 완벽히 합법적인 반쪽 산책이다 — validity를 arrival-by-length로 지불한 것으로, P3가 ~19토권을 이식해야 했고 합성 EM이 낮게 남은 이유가 정확히 이것이다. 이는 §6.9의 판정을 더 선명하게 한다: mask의 "결단력 있 지만 거친" 실패가 수리 비용이 더 싼 쪽이다.

6.10 Forward 커널 ablation: GDP graph-CTMC vs. 순수 uniform-state (D3PM)

두 forward 커널. GDP의 커널은 도로 그래프를 따라 확산한다: (<end>-확장) 인접행렬로 만든 generator $G = A' - D'$ 로

$$Q_t^{graph} = \exp((A' - D') \beta_t) \text{ — 국소 이동, 느린 전역 혼합(작은 스펙트럴 갭), } x_t \text{에 그래프 구조가 보존됨.}$$

고전적인 순수 uniform-state 커널은 완전 그래프 특수 사례 $A' = \mathbb{1}\mathbb{1}^T$ 이며 닫힌 형태를 갖는다:

$$Q_t^{unif} = e^{-K\beta_t} I + (1 - e^{-K\beta_t}) \mathbb{1}\mathbb{1}^T/K \Leftrightarrow \tilde{\alpha}_t = e^{-K \sum_{s \leq t} \beta_s} \text{인 D3PM-uniform } (K = V+1 \text{ 상태}),$$

즉 생존-또는-균등-순간이동 — 그래프 구조가 어디에도 없다. 같은 Destroyer에 완전 그래프를 넘겨 구현; 완전 그래프의 스펙트럴 갭이 K라 원래 스케줄이면 t = 2에 완전히 섞이므로 β 를 1/K로 스케일($7 \times 10^{-8} \cdots 7.2 \times 10^{-3}$)해 스텝당 생존 프로파일을 graph 커널과 정렬; connectivity loss는 끄고 내장 제약 디코드는 완전 그래프라 자

동 무제약 — 구성상 "순수" 세팅. 백본-데이터·1 epoch 예산(48.9분)·D3PM ELBO·blk64(=full canvas)·\$6.8 프로토콜 전부 동일.

구성	변형	arrival	valid	EM	PC	inv-edge	rem-edge	patch	ESS
base	raw	0.086	0.001	0.001	0.001	82.9%	0.9%	—	—
	P1+P3	1.000	1.000	0.002	0.032	0%	0%	58.8	—
modelD	raw	0.092	0.006	0.005	0.006	82.3%	1.0%	—	91.3
	P1+P3	1.000	1.000	0.017	0.048	0%	0%	58.0	—
adj+modelD	raw	0.002	0.967	0.084	0.342	0.0%	0.0%	—	91.3
	P1+P3	1.000	1.000	0.066	0.250	0%	0%	20.2	—

- **순수 uniform 커널은 이 과제에서 붕괴한다:** raw valid 0.001, invalid edge 82.9% — 거의 전부 *alien*(rem-edge는 0.9%뿐)으로, 사실상 무작위 정점 수열이다. P1이 경로당 53토큰(경로 길이의 3배)을 이식해야 하고 어떤 처리를 해도 $EM \leq 0.07$. 같은 예산의 graph forward는 valid 0.460, inv-edge 5.1% — **GDP의 그래프-구조 forward가 uniform-state diffusion을 성립시키는 요소**이며, 노이즈의 국소성은 장식이 아니라 0.46과 0.001의 차이이다.
- **guidance는 이를 구하지 못하며, 그 이유가 negative-class 설계에 교훈을 준다:** model-negative disc는 학습 정확도 0.999(자기 negative — 모델의 unconditional 샘플 — 가 자명하게 구분되는 쓰레기라서)에 도달하지만 실제 경로에는 **우연 수준(0.527)**으로만 전이된다. D가 "예외인가?"가 아니라 "무작위 수열인가?"를 배운 것이다. p_0 가 데이터 매니폴드에서 아주 멀면 Eq. 2의 분포 클래스가 정착 필요한 곳에서 신호를 갖지 못한다 — data/mix negative가 더 잘 다룰 옛지 케이스.
- **하드 제약만이 유일한 지렛대:** A_{exc} -제약 디코드가 validity를 0.967로 올리지만, 걷기는 graph64보다 더 길을 잃는다 (endpoint patch 20토큰; 합성 EM 0.066, 세 커널 중 최하).
- **Full-canvas 커널 순위** (raw valid / P1+P3 후 EM): mask64 0.15 / 0.234 · graph64 0.46 / 0.105 · uniform64 0.001 / 0.066 — forward의 구조는 validity를 사고(graph > mask > uniform), 디코딩의 결단력은 arrival과 최종 품질을 산다(mask >> graph >> uniform).

7. 발표된 baseline과의 비교: D-CBG (Schiff et al.)

7.1 발표된 형태 그대로의 비교

kuleshov-group/discrete-diffusion-guidance 의 plug-in 이식 (이 저장소 파일 수정 0건; dcbg_plugin.py 가 그들의 _cbg_denoise 로직을 담음): **노이즈-조건 분류기** $p(y \mid x_t, t)$ — 그들 프로토콜: 라벨된 데이터(exceptional vs normal, 같은 1% 예산/split)를 생성 시점 forward corruption으로 오염 — 가 posterior를 $y \cdot \log p(y \mid x_t^{\ell \rightarrow k})$ 로 기을인다. mask 커널: 공개 위치에서의 **exact 열거**(first-hitting 하에서 정확; reveal당 |V|회 분류기 호출); graph 커널: 그들의 **1차 (Taylor) 근사**. $y \in \{1, 2, 4\}$; 평가 동일.

구성	방법	arrival	valid	EM raw	rem-edge	inv-edge	EM P1+P3	PC P1+P3	s/path
mask blk4	base	0.963	0.242	0.222	5.1%	6.4%	0.257	0.417	0.01
	D-CBG $\gamma=4$ (최적 γ)	0.907	0.267	0.248	2.2%	9.0%	0.309	0.436	2.7
	우리 (IW, modelD)	0.952	0.327	0.291	5.0%	5.5%	0.306	0.461	0.03
	우리 (adj+modelD)	0.861	0.372	0.315	2.9%	4.8%	0.331	0.476	0.05
mask blk64	base	0.874	0.151	0.120	4.9%	8.6%	0.193	0.361	0.01
	D-CBG $\gamma=4$	0.844	0.156	0.124	2.2%	9.6%	0.228	0.386	2.7
	우리 (adj+modelD)	0.806	0.251	0.183	3.0%	6.8%	0.234	0.401	0.09
graph blk64	base	0.043	0.460	0.080	5.1%	5.1%	0.051	0.233	0.06
	D-CBG $\gamma \in \{1, 2, 4\}$	0.025	0.459-0.470	0.085	5.0%	5.0%	0.054	0.235	2.8
	우리 (adj+modelD)	0.007	0.985	0.220	0.0%	0.0%	0.105	0.307	0.09

분류기 검증 정확도 (그들 프로토콜, 생성 시점 corruption 기준): mask blk4 0.719, mask blk64 0.734 — 우리 disc와 비슷 — 그러나 graph/CTMC는 **0.512 (우연 수준)**: uniform-CTMC로 오염된 경로에서 노이즈-상태 분류기가 이 데이터 예산으로는 학습되지 않아 graph D-CBG는 무력(해당 행 $\approx$ base). 우리의 클린 부분-경로 discriminator(Lemma 1 정식화)는 노이즈-상태 분류 자체를 우회한다.

- **D-CBG가 진짜 강한 지점:** 위치별 열거 덕에 removed edge를 직접 벌줄 수 있다 — $\gamma = 4$ 에서 비-인접행렬 방법 중 최저 removed-edge율(2.2%, 우리 순수 재가 중 5.0% 대비). 단 $\gamma = 4$ 는 되어야 작동한다 ($\gamma \leq 2 \approx$ base).
- **그 대가:** 위치별 tilting이 모델의 결합분포와 싸우면서 전체 invalid edge가 증가(blk4: 6.4% $\rightarrow$ 9.0%; removed가 alien으로 대체됨)하고 arrival이 하락. 우리의 joint 후보 재가중은 후보가 구성상 모델-일관적이라 validity와 EM이 **함께** 개선된다.
- **End-to-end에서는 모든 셀에서 우리가 우세:** blk4 합성 EM/PC 0.331/0.476 (우리) vs 0.309/0.436 (D-CBG 최적 γ); blk64·graph64도 동일 — 그것도 **guidance 비용 30-90배 절감**(0.03-0.09 vs exact 열거 $\approx$ 2.7 s/path)으로.

- **시나리오 전이:** D-CBG 분류기는 인접행렬을 입력받지 않아 새 시나리오마다 재학습이 필요; 우리 discriminator는 unseen 시나리오로 일반화(\$6.2, 실험 2) — 논문 비교표가 가져야 할 열.

7.2 통제된 2x2: 메커니즘 × 분류기, 나머지 전부 일치

\$7.1은 guidance 메커니즘과 분류기 설계가 교락되어 있었다. 이번 라운드는 이를 통제한다: 네 셀 모두 동일한 분류기 아키텍처(임베딩 · GraphSAGE · edge-existence/deg-ratio 채널 · 인코더 · masked pooling · bounded logit · label smoothing)와 동일한 학습 프로토콜(라벨 데이터: exceptional 1% vs normal, 같은 split)을 공유한다. 남은 차이는 방법 내재적인 것뿐: D-CBG의 분류기는 수식이 요구하는 대로 노이즈 상태 (x_t, t)를 읽고, 우리는 Lemma 1이 요구하는 대로 *클린 부분 경로를 읽는다* — 그리고 출력의 사용 방식(위치별 tilting vs joint 후보 재가중). 2x2에는 proposal 마스킹 없음(별도의 합성 가능한 레버로 유지).

구성	셀	clf val	arrival	valid raw	inv-edge	rem-edge	EM P1+P3
mask blk4	D-CBG + plain ($\gamma=4$)	0.719	0.907	0.267	9.0%	2.2%	0.309
	D-CBG + adj ($\gamma=4$)	0.746	0.939	0.289	6.1%	4.4%	0.290
	D-CBG + adj, first-order (모든 γ)	0.746	0.962	0.245	6.4%	5.1%	0.260
	IW + plain	0.676	0.948	0.255	6.4%	4.9%	0.271
	IW + adj	0.71	0.950	0.307	5.7%	5.0%	0.300
mask blk64	D-CBG + plain ($\gamma=4$)	0.734	0.844	0.156	9.6%	2.2%	0.228
	D-CBG + adj ($\gamma=4$)	0.750	0.844	0.181	8.4%	3.5%	0.214
	D-CBG + adj, first-order (모든 γ)	0.750	0.871	0.152	8.6%	4.8%	0.194
	IW + plain	0.676	0.883	0.172	8.6%	4.6%	0.204
	IW + adj	0.71	0.885	0.210	8.4%	4.8%	0.221
graph blk64	D-CBG + adj (모든 γ)	0.531	0.03	0.466-0.469	5.0%	5.0%	0.056
	IW + adj (data)	0.71	0.015	0.656	5.0%	5.0%	0.080
	IW + plain (ESS 31!)	0.676	0.019	0.708	4.1%	4.1%	0.084

IW 행은 guidance만(proposal 마스킹 없음); "IW + adj" 셀은 \$6.1의 data-negative 런 재사용(그 런에서는 합성 EM 미측정). 모든 구성에서 $\gamma \leq 2$ 의 D-CBG는 $\approx$ base. 합성 가능한 adjacency-masked proposal을 얹으면 IW + plain이 blk4에서 valid 0.327, 그리고 graph64의 새로운 최고 기록 — **valid 0.988, raw EM 0.233** (IW + plain + adj-proposal) — 에 도달한다.

- **비용-품질 프론티어가 비교를 완결한다.** D-CBG의 저렴한 변형 — reveal당 분류기 forward+backward 1회의 first-order/Taylor 근사(~ 48 회/경로, 0.07 s/path) — 는 **모든 γ 에서 무력하다** (blk4 valid 0.245 $\approx$ base 0.242; blk64 0.152 $\approx$ 0.151): one-hot MASK 임베딩에서 취한 gradient가 이 도메인에서는 유효한 치환 신호를 담지 못한다. 작동하는 변형 — exact 열거 — 는 $\gamma = 4$ 에서만 효과가 있고 $\sim 33k$ 회(2.7 s/path)가 든다. 우리 IW는 그 사이($\sim 2.4k$ 회, 0.03-0.05 s/path)에서 가장 큰 개선을 낸다: **싼 D-CBG는 작동하지 않고, 작동하는 D-CBG는 싸지 않다.**
- **사용자 가설이 실증됨: adjacency-aware 분류기는 두 방법 모두를 돕는다.** D-CBG는 두 block size에서 valid +2.2-2.5%p (clf val 0.72 $\rightarrow$ 0.75), 그리고 더 흥미롭게도 adjacency 채널이 *D-CBG의 일관성 손상을 제거*한다 (blk4 inv-edge 9.0% $\rightarrow$ 6.1%): 합법성을 직접 보게 되니 alien edge를 만들어내던 극단적 tilt가 불필요해진다.
- **분류기를 맞추면 두 메커니즘의 격차는 \$6.11이 시사한 것보다 좁다:** adj-vs-adj에서는 IW 승(0.306 vs 0.289; 0.205 vs 0.181); plain-vs-plain은 갈림(blk4는 D-CBG 0.267 > IW 0.255; blk64는 IW 0.172 > D-CBG 0.156). 따라서 메커니즘 수준에서 IW의 정확한 주장은: 조정할 γ 가 없음(D-CBG는 $\gamma = 4$ 미만에서 무력), arrival 보존(0.95 vs 0.84-0.94), 30-90배 낮은 비용, proposal 마스킹과의 자유로운 합성.
- **구조적 논거는 통제 후에도 생존:** adjacency 아키텍처를 맞춰도 D-CBG의 분류기는 CTMC 커널에서 우연 수준(0.531) — 병목은 아키텍처가 아니라 노이즈-입력 분류 문제 자체이며, 이를 우회하는 클린-부분-경로 입력은 IW 정식화(Lemma 1)에서만 가능하다. graph 커널에서 메커니즘 격차는 결정적: 0.47 (D-CBG) vs 0.71 (IW).
- **예상 밖의 발견:** graph 커널에서는 PLAIN 부분-경로 discriminator가 adjacency-aware보다 잘 유도한다 (valid 0.708 vs 0.656), 그것도 극적으로 날카로운 가중치(ESS 31 vs 96 — 이 프로젝트 전체에서 처음 관측된 50 미만 ESS)로. adjacency 피처가 정작 시퀀스-수준 단서가 판별 신호인 지점에서 후보 점수를 균질화하는 것으로 보인다: 설계 규칙을 끌어내기 전에 전용 ablation이 필요하다.

Matched 분류기 하의 unseen 시나리오 전이 (실험 2). adjacency-aware D-CBG 분류기를 except 1-99 (각 1%, 배치별 시나리오 인접행렬 — \$6.2 프로토콜)로 학습하고 unseen except_0에서 평가:

blk	방법 (unseen, e99 학습)	clf val (unseen)	valid raw	seen(e0) 대비	EM P1+P3
4	D-CBG + adj ($\gamma=4$)	0.703	0.292	0.289 $\rightarrow \pm 0$	0.281
	IW + adj (우리, \$6.2)	≈ 0.71	0.314	0.306 $\rightarrow \pm 0$	0.302
64	D-CBG + adj ($\gamma=4$)	0.684	0.161	0.181 $\rightarrow -2.0\%p$	0.199
	IW + adj (우리)	≈ 0.71	0.210	0.210 $\rightarrow \pm 0$	0.212

IW 행의 EM P1+P3와 blk64 행은 e99 disc의 three-way 재실험에서 측정 (blk4 valid 재실험값 0.323 — $\pm 1.5\%p$ 표본 노이즈 이내; seen 대비의 blk64 기준값 0.210은 같은 시드의 e0-data 재실험).

- 일반화는 guidance 메커니즘이 아니라 adjacency-조건 분류기 설계의 속성이다: adjacency 채널(우리의 정식화; 이 절에서 D-CBG에 이식)만 주어진다면 두 방법 모두 blk4에서 사실상 손실 없이 unseen 시나리오로 전이한다 (D-CBG 0.289 → 0.292; 우리 0.306 → 0.314). 이는 §7.1 마지막 항목을 완화한다: 발표된 D-CBG(인접행렬 입력 없음)는 시나리오별 재학습이 필요하지만, 그 능력 자체는 이식 가능하다. 따라서 논문의 정직한 주장은: **재학습 없는 전이를 가능케 하는 시나리오-조건 분류기 설계는 우리의 기여이며 — 어떤 classifier-guidance 메커니즘에도 이식 가능 — 그 위에서도 우리 IW 메커니즘의 우위가 유지된다** (unseen blk4: 0.314 vs 0.292, seen과 같은 순서).

7.3 가장 순수한 프로토콜: 두 방법 모두 모델-분포 negative

마지막 통제: 두 분류기를 같은 negative 소스 — 각 블록의 unconditional 생성 20k (§6.7의 pool) — 로 학습하되, 각자 방법의 입력 형태대로 가공 (D-CBG: 생성 시점 노이즈; 우리: 클린 랜덤 절단 부분 경로). positive-split-아키텍처(adjacency-aware)는 불변. 아래 표는 §7.2의 data-negative 결과를 나란히 배치해 **negative class(일반 데이터 vs 모델 생성)의 효과를 방법별로 직접 비교**한다 (data-negative 행은 §7.2/캡션 재실행의 동일 프로토콜 측정값).

blk	방법	negative	clf val	arrival	valid raw	EM raw	EM P1+P3	PC P1+P3
4	D-CBG + adj ($\gamma=4$)	일반 데이터	0.746	0.939	0.289	0.258	0.290	0.444
	D-CBG + adj ($\gamma=4$)	모델 생성	0.828	0.945	0.298	0.264	0.291	0.444
	IW (우리)	일반 데이터	≈ 0.71	0.950	0.307	0.278	0.300	0.455
	IW (우리)	모델 생성	≈ 0.83	0.952	0.327	0.291	0.306	0.461
	IW + adj-proposal	일반 데이터	≈ 0.71	0.861	0.361	0.307	0.323	0.471
	IW + adj-proposal	모델 생성	≈ 0.83	0.861	0.372	0.315	0.331	0.476
8	D-CBG + adj ($\gamma=4$)	일반 데이터	0.750	0.923	0.254	0.233	0.280	0.437
	D-CBG + adj ($\gamma=4$)	모델 생성	0.844	0.932	0.269	0.240	0.287	0.443
	IW (우리)	일반 데이터	≈ 0.71	0.935	0.283	0.264	0.306	0.456
	IW (우리)	모델 생성	≈ 0.83	0.936	0.299	0.277	0.307	0.458
	IW + adj-proposal	일반 데이터	≈ 0.71	0.872	0.334	0.298	0.345	0.486
	IW + adj-proposal	모델 생성	≈ 0.83	0.868	0.351	0.312	0.350	0.488
16	D-CBG + adj ($\gamma=4$)	일반 데이터	0.758	0.890	0.222	0.185	0.220	0.389
	D-CBG + adj ($\gamma=4$)	모델 생성	0.887	0.876	0.238	0.192	0.223	0.394
	IW (우리)	일반 데이터	≈ 0.71	0.895	0.238	0.205	0.244	0.400
	IW (우리)	모델 생성	≈ 0.83	0.895	0.252	0.217	0.250	0.406
	IW + adj-proposal	일반 데이터	≈ 0.71	0.821	0.277	0.233	0.276	0.429
	IW + adj-proposal	모델 생성	≈ 0.83	0.822	0.288	0.241	0.283	0.435
32	D-CBG + adj ($\gamma=4$)	일반 데이터	0.727	0.852	0.188	0.147	0.222	0.386
	D-CBG + adj ($\gamma=4$)	모델 생성	0.875	0.867	0.207	0.160	0.222	0.390
	IW (우리)	일반 데이터	≈ 0.71	0.872	0.197	0.157	0.206	0.366
	IW (우리)	모델 생성	≈ 0.82	0.875	0.219	0.174	0.217	0.375
	IW + adj-proposal	일반 데이터	≈ 0.71	0.811	0.236	0.184	0.235	0.394
	IW + adj-proposal	모델 생성	≈ 0.82	0.809	0.252	0.196	0.239	0.397
64	D-CBG + adj ($\gamma=4$)	일반 데이터	0.750	0.844	0.181	0.139	0.214	0.384
	D-CBG + adj ($\gamma=4$)	모델 생성	0.824	0.848	0.191	0.142	0.223	0.390
	IW (우리)	일반 데이터	≈ 0.71	0.885	0.210	0.163	0.221	0.381
	IW (우리)	모델 생성	≈ 0.82	0.888	0.222	0.173	0.220	0.379
	IW + adj-proposal	일반 데이터	≈ 0.71	0.810	0.239	0.176	0.236	0.402
	IW + adj-proposal	모델 생성	≈ 0.82	0.806	0.251	0.183	0.234	0.401

- **전 블록 확장 (blk 8/16/32 추가):** 모든 순서가 전 블록에서 재현된다 — 두 negative 모두에서 IW > D-CBG (valid raw 비교 10/10), 두 방법 모두에서 model > data negative, 그 위의 adj-proposal이 모든 블록의 최고 셀. $\gamma = 4$ 고정 = blk4/64의 단조 sweep 근거. 정직한 예외 하나: blk32의 합성 EM은 통계적 동률 (D-CBG 0.222 vs IW 0.217-0.239) — 큰 블록에서는 후처리가 합성 지표의 격차를 좁힌다.
- **모델 negative는 세 번째 이식 가능한 자료:** adjacency 채널(§7.2)처럼 D-CBG도 개선한다 (blk4 valid 0.289 → 0.298, blk64 0.181 → 0.191; 분류기 val 0.75 → 0.83) — §6.7의 data < model 순서가 상대방에서도 재현.

- 가장 순수한 matched 프로토콜에서 IW 우위는 오히려 약간 벌어진다: blk4 +2.9%p (0.327 vs 0.298), blk64 +3.1%p (0.222 vs 0.191), 각각 $\approx 2\sigma$ — data negative 시절의 +1.7/+2.4%p 대비 — 그리고 완성형(adj-proposal)은 두 block size의 모든 열에서 최고.
- §7 비교의 총정리: 우리가 정식화한 세 재료 — 시나리오-조건 분류기 (§7.2), 모델-분포 negative(본 절), Lemma 3 proposal 마스킹(구조상 우리 전용) — 는 classifier guidance에 이식되거나 합성된다. D-CBG는 앞의 둘로 개선되지만, 모든 matched 구성(data/model negative $\times$ plain/adj 분류기 $\times$ seen/unseen)에서 joint-후보 IW 메커니즘이 최고점을 기록하고, γ 튜닝이 없으며, arrival을 보존하고, 비용 프론티어의 유리한 지점을 차지한다.

8. 이전 보고서(RESULTS_BD_prev.pdf)와의 관계

- 이전 보고서는 blk4만, refine 변형과 함께 평가: mask raw 0.952 arrival / 0.820 valid $\wedge$ hit, refine_es +0.03 arrival, refine_nx는 구조상 arrival 1.0. 본 sweep은 refine을 전부 제거(사용자 요청)하고 block size를 변화시켰다.
- 이전 보고서의 "mask 커널에는 refinement가 거의 불필요"라는 결론은 여기서 더 강해진다: blk1의 raw arrival 0.997 — refinement의 여지가 $\leq 0.3\%$.
- graph(uniform-state CTMC) 커널은 이 sweep에 포함되지 않았다(사용자 결정: mask만). 이전 보고서의 대기 작업(d = 0.05 재학습, respaced block sampling)은 미결로 남는다.

산출물

- 체크포인트: sets_model/BD_porto_v3_normal_mask_blk{1,2,4,8,16,32,64}_base_bd.pth (+ _epoch_0), 서버 143.248.84.179:/home/aailab/wp03052/Synthetic-Data/Block-Diffusion-0D-Planning
- 결과: sets_res/BD_porto_v3_normal_mask_blk*_base_bd.res (raw + refine_nx + refine_es 저장; 본 보고서는 raw만), 후처리 비교 sets_res/BD_mask_blk*_postproc.res (eval_bd_postproc.py) + 경로별 EM/PC 기록 sets_res/em_pc/
- 학습 로그: sets_log/bd_mask_blk*.log , sets_model/*_bd_train_log.txt
- 코드: models_seq/bd_models.py , models_seq/bd_trainer.py , main_bd.py , train_porto_bd.sh ; 실행: tmux 세션 bd_gpu{0..3} (GPU 당 1런)
- Guidance: discriminator sets_disc/BDdisc_*.pth + pool sets_disc/neg_pool.pth ; 결과 sets_res/BDguid_*.res ; 코드 models_seq/bd_disc.py , bd_models.py::plan_guided , train_bd_disc.py , eval_bd_guidance.py , run_bd_guidance_all.sh
- 문서: 코드 검증 pdfs/BD_CODE_VERIFICATION_K0/EN.pdf ; guidance 수식 pdfs/BD_GUIDANCE_FORMULATION.pdf ; 본 보고서 영어판 pdfs/RESULTS_BD.pdf