

IW guidance의 γ -tempering: 수학적 정식화

가중치 지수 w_γ 가 정의하는 목표 분포와 그 성질

2026-07-31

이 노트는 다음 질문에 답한다: D -CBG의 *guidance* 세기 γ 처럼, 우리 IW *guidance*의 가중치도 하이퍼파라미터로 키울 수 있는가? 그때 샘플러가 겨냥하는 분포를 수학적으로 정의할 수 있는가? 답은 둘 다 “예”이며, 해당 파라미터는 코드에 이미 존재한다 (`bd_models.py::plan_guided`의 `w_gamma`; 본 기록의 모든 실험은 $\gamma_w = 1$ 고정). 아래에서 $\gamma \equiv \gamma_w$ 로 쓴다.

1 설정

이산 상태공간 $\mathcal{X}$ (한 reveal 위치에서는 vocab, 블록 단위로는 블록 후보 공간) 위에 두 분포를 둔다: 참조 분포 p_θ (backbone이 제안하는 분포)와 목표 분포 q (시나리오 조건 경로 분포). 판별자 D 는 양성 $\sim q$, 음성 $\sim p_\theta$ 의 균형 표본으로 학습된 이진 분류기이고, 그 로짓을 $\ell(x)$ 라 한다.

Assumption 1 (이상적 판별자). 균형 학습의 Bayes 최적해에서

$$D^*(x) = \frac{q(x)}{q(x) + p_\theta(x)}, \quad \ell^*(x) = \log \frac{D^*(x)}{1 - D^*(x)} = \log \frac{q(x)}{p_\theta(x)}.$$

즉 로짓은 밀도비(density ratio)의 로그이다. 이하의 명제는 $\ell = \ell^*$ 일 때의 진술이고, 학습된 $\ell \approx \ell^*$ 에서는 근사적으로 성립한다.

우리의 guided reveal은 self-normalized importance sampling (SNIS)이다: 후보 $x^{(1)}, \dots, x^{(n)} \stackrel{iid}{\sim} p_\theta$ ($n = n_{is} = 100$)를 뽑고, 가중치

$$w_i = \exp(\gamma \ell(x^{(i)})) = \left(\frac{D}{1-D}(x^{(i)}) \right)^\gamma$$

로 재가중한 뒤, 정규화된 가중 평균 $\bar{x}_0 = \sum_i \tilde{w}_i x^{(i)}$ ($\tilde{w}_i = w_i / \sum_j w_j$)를 reveal 목표로 쓴다. 본 기록은 $\gamma = 1$ 이다.

2 γ 가 정의하는 목표 분포

Definition 1 (geometric bridge / tempered 목표). $\gamma \geq 0$ 에 대해

$$p_\gamma(x) := \frac{q(x)^\gamma p_\theta(x)^{1-\gamma}}{Z_\gamma}, \quad Z_\gamma = \sum_{x \in \text{supp } p_\theta} q(x)^\gamma p_\theta(x)^{1-\gamma}.$$

$\mathcal{X}$ 가 유한하므로 Z_γ 는 항상 유한하고, $Z_\gamma > 0$ 인 한 p_γ 는 잘 정의된 분포이다.

Proposition 1 (임의의 γ 에서의 SNIS 일치성). 가정 1 하에서, 임의의 유계 f 에 대해

$$\frac{\sum_{i=1}^n w_i f(x^{(i)})}{\sum_{i=1}^n w_i} \xrightarrow[n \rightarrow \infty]{a.s.} \mathbb{E}_{p_\gamma}[f(x)].$$

즉 γ -가중 SNIS 샘플러가 겨냥하는 분포는 정확히 p_γ 이다.

Proof. 대수의 법칙으로 분자 $\frac{1}{n} \sum_i w_i f(x^{(i)}) \rightarrow \mathbb{E}_{p_\theta}[f(x) (q/p_\theta)^\gamma(x)] = \sum_x f(x) q^\gamma p_\theta^{1-\gamma}(x) = Z_\gamma \mathbb{E}_{p_\gamma}[f]$, 분모 $\frac{1}{n} \sum_i w_i \rightarrow Z_\gamma$. 두 극한의 비가 결과를 준다. $\square$

Corollary 1 (특수값). (i) $\gamma = 0$: $p_0 = p_\theta$ (guidance 꺼짐). (ii) $\gamma = 1$: $p_1 = q$ — 현재 기록의 추정량이 겨냥하는 분포 (기존 SNIS 일치성의 재확인). (iii) $0 < \gamma < 1$: p_θ 와 q 사이의 *geometric interpolation*. (iv) $\gamma > 1$: q 를 지나 밀도비가 큰 영역으로 *sharpening*하는 *extrapolation (tempering)*.

3 목표 분포는 γ 에 따라 정확히 어떻게 움직이는가

정의 1를 다시 쓰면, $\{p_\gamma\}_{\gamma \geq 0}$ 는 p_θ 를 지나는 **exponential tilting** 족이다:

$$p_\gamma(x) \propto p_\theta(x) e^{\gamma \ell(x)}, \quad \ell(x) = \log \frac{q(x)}{p_\theta(x)},$$

즉 로그밀도가 γ 에 대해 선형으로 움직이는 1-파라미터 지수족이고, γ 가 natural parameter, ℓ 이 충분통계량이다. 이 관점에서 “분포가 어떻게 바뀌는가”는 닫힌 형태로 완전히 답해진다.

Proposition 2 (이동의 방향과 속도). (i) 점별 이동:

$$\frac{\partial}{\partial \gamma} \log p_\gamma(x) = \ell(x) - \mathbb{E}_{p_\gamma}[\ell].$$

즉 매 순간, 밀도비가 그 시점의 평균보다 높은 상태는 질량을 얻고 낮은 상태는 잃는다.

(ii) 두 상태 사이의 상대 확률:

$$\frac{p_\gamma(x)}{p_\gamma(x')} = \frac{p_\theta(x)}{p_\theta(x')} \cdot e^{\gamma(\ell(x) - \ell(x'))}$$

— γ 가 1 늘 때마다 로짓 차이만큼 지수적으로 벌어진다.

(iii) 단조성: $\frac{d}{d\gamma} \mathbb{E}_{p_\gamma}[\ell] = \text{Var}_{p_\gamma}(\ell) \geq 0$. 즉 목표 분포가 보는 평균 밀도비는 γ 에 대해 단조 증가하고, 증가 속도는 그 시점의 로짓 분산이다 (분산이 작으면 — 한 상태에 질량이 몰리면 — 이동도 멈춘다).

(iv) 극한: $\gamma \rightarrow \infty$ 에서 p_γ 는 $\arg \max_x \ell(x)$ (지지집합 $\text{supp } p_\theta$ 안에서 밀도비가 최대인 상태들)의 균등분포로 수렴한다.

Proof. (i),(iii)은 지수족의 표준 항등식($\log Z_\gamma$ 의 1,2차 도함수가 ℓ 의 평균·분산). (ii)는 정의에서 즉시. (iv)는 (ii)에서 ℓ 최대 상태 대비 나머지의 비가 0으로 가는 것으로부터. $\square$

Remark 1 ($\gamma > 1$ 이 향하는 곳은 q 의 mode가 아니다). (iv)가 주는 주의점: γ 를 계속 키우면 분포는 q 가 큰 곳이 아니라 밀도비 q/p_θ 가 큰 곳으로 간다. 수치 예로, 상태 3개에 $p_\theta = (0.70, 0.25, 0.05)$, $q = (0.20, 0.50, 0.30)$ 이면 (밀도비 0.29, 2.0, 6.0):

	x_1	x_2	x_3
$\gamma = 0$ ($= p_\theta$)	0.700	0.250	0.050
$\gamma = 0.5$	0.440	0.416	0.144
$\gamma = 1$ ($= q$)	0.200	0.500	0.300
$\gamma = 2$	0.020	0.350	0.630
$\gamma = 4$	0.000	0.058	0.942

$\gamma = 1$ 까지는 정확히 q 로 가지만, 그 뒤로는 q 의 mode인 x_2 ($q = 0.5$)가 아니라 p_θ 대비 가장 “이례적인” x_3 (비 = 6)에 질량이 몰린다. 우리 과제로 번역하면: $\gamma > 1$ 은 “시나리오에서 상대적으로 가장 그럴듯해진 경로”를 과대표집한다 — validity를 밀어올리되 reference 경로 분포에서 멀어질 수 있는, §5.8–5.9에서 관측된 validity↑/arrival↓ 맞교환의 분포적 근원이다.

Remark 2 (D-CBG의 γ 와의 대응). D-CBG는 위치별 posterior를 $p_\phi(y|x)^\gamma$ 로 기울인다. 가정 1의 표기로 $p_\phi(y=1|x) = \sigma(\ell(x))$ 이므로 두 방법의 tilt는

$$\text{IW: } e^{\gamma \ell(x)}, \quad \text{D-CBG: } \sigma(\ell(x))^\gamma = \left(\frac{e^\ell}{1+e^\ell} \right)^\gamma.$$

둘 다 ℓ 에 단조이므로 후보 순위는 동일하게 움직이지만 꼬리 거동이 다르다: $\sigma(\ell)^\gamma$ 는 $\ell \gg 0$ 에서 1로 포화해 나쁜 후보의 억제만 무한히 강해지는 반면, $e^{\gamma \ell}$ 은 위로도 계속 증가해 좋은 후보의 증폭까지 한다. $\gamma = 1$ 에서 IW는 q 를 정확히 겨냥하고(따름정리 1), D-CBG는 Bayes posterior tilt로서 정확하다. $\gamma \neq 1$ 에서는 둘 다 Bayes를 떠나 서로 다른 파라미터화의 tempered 죽이 된다 — 어느 쪽도 “더 원리적”이지 않고, 같은 종류의 하이퍼파라미터이다.

4 유한 표본에서 일어나는 일: ESS가 γ 의 상한을 정한다

명제 1은 $n \rightarrow \infty$ 의 진술이다. 유한한 $n = 100$ 에서 SNIS 추정량의 편향은 유효표본크기

$$\text{ESS} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2} \in [1, n]$$

로 통제되며(표준 결과: 편향 = $O(1/\text{ESS})$), γ 를 키우면 ESS가 떨어진다.

Proposition 3 (유계 로짓 하의 ESS 하한). $|\ell(x)| \leq L$ (우리 판별자는 tanh bound로 $L = 4$)이면 $w_{\max}/w_{\min} \leq e^{2\gamma L}$ 이고,

$$\text{ESS} \geq n e^{-2\gamma L}.$$

또한 후보들 위에서 ℓ 의 분산을 σ_ℓ^2 라 하면 log-normal 근사에서 $\text{ESS} \approx n e^{-\gamma^2 \sigma_\ell^2}$: ESS는 γ 에 대해 대략 가우시안 꼴로 감소한다.

증명 (하한). $\text{ESS} = (\sum w)^2 / \sum w^2 \geq (n w_{\min})^2 / (n w_{\max}^2) = n (w_{\min}/w_{\max})^2 \cdot (w_{\max}/w_{\min}) \geq n e^{-2\gamma L}$. □

Proposition 4 ($\gamma \rightarrow \infty$ 극한). 고정된 후보 집합 $\{x^{(i)}\}_{i=1}^n$ 에서 $\gamma \rightarrow \infty$ 이면 (동률이 없는 한) $\tilde{w} \rightarrow \text{one-hot at } \arg \max_i \ell(x^{(i)})$. 즉 샘플러는 판별자로 재순위한 best-of- n 으로 퇴화한다.

이 극한은 실험 기록의 E1(②) arm과 정확히 연결된다: γ 축의 한쪽 끝($\gamma = 0$)은 unguided base, $\gamma = 1$ 은 현행 guidance, $\gamma = \infty$ 는 discriminator-reranked best-of-100이다. γ 스윙은 이 세 지점을 잇는 연속 곡선을 그리는 셈이다.

¹중간 부등식은 $\sum w \geq n w_{\min}$, $\sum w^2 \leq n w_{\max}^2$ 에서. 근사식은 $\log w_i \sim \mathcal{N}(\gamma \mu_\ell, \gamma^2 \sigma_\ell^2)$ 일 때 $\text{ESS}/n \approx e^{-\gamma^2 \sigma_\ell^2}$ 인 표준 계산.

Remark 3 (실측 여유). $\gamma = 1$ 에서 측정된 reveal당 평균 ESS는 $\approx 95\text{--}99.7/100$ (v4 보고서 §5.4)이다. 명제 3의 근사로 역산하면 $\sigma_\ell^2 \lesssim 0.05$ 수준이므로, $\text{ESS} \geq 50$ 을 유지하는 조건 $\gamma^2 \sigma_\ell^2 \leq \log 2$ 는 $\gamma \lesssim 3.7\text{--}8$ 범위를 허용한다. 즉 $\gamma \in \{2, 4\}$ 정도는 편향 폭발 없이 시도할 수 있고, 실제 상한은 ESS 로그로 실측하면 된다.

5 기존 구성요소와의 정합성

Remark 4 (Lemma 3 마스킹은 모든 $\gamma > 0$ 에서 그대로 성립). Lemma 3의 논증은 “제외되는 후보는 목표 분포에서 가중치 0”이다. 시나리오-불법 후보 x 는 $q(x) = 0$ 이므로 임의의 $\gamma > 0$ 에서 $q(x)^\gamma p_\theta(x)^{1-\gamma} = 0$, 즉 $p_\gamma(x) = 0$. 따라서 인접성 제약 제안(adj_prop)과 γ -tempering의 결합은 $\gamma = 1$ 일 때와 동일한 이유로 정확(exact)하다.

Remark 5 (제안분포 보정은 지수화되지 않는다). ancestral 후보 (E6)처럼 제안이 p_θ 가 아니라 $r(x)$ 일 때 올바른 가중치는

$$w_i = \left(\frac{q}{p_\theta}\right)^\gamma (x^{(i)}) \cdot \frac{p_\theta(x^{(i)})}{r(x^{(i)})}$$

이다: tempering은 목표에 대한 조작이므로 밀도비 항에만 γ 가 붙고, 제안 보정항은 항상 1승이다. 현재 구현 $g = w_gamma * dlogits + log_a$ 가 정확히 이 형태이므로 코드 수정 없이 성립한다.

Remark 6 (블록/lookahead 구조 불변). γ 는 스칼라 가중치 w_i 의 정의만 바꾼다. 블록 전체 후보에 가중치를 broadcast하고 한 위치만 커밋하는 구조, 커밋 토큰의 tilt가 $\mathbb{E}[w \mid x_k = v]$ (한 수 앞 rollout의 주변화)라는 해석, ESS 계측 — 모두 $\gamma = 1$ 일 때와 동일한 형태로 유지된다.

6 요약

- IW 가중치의 지수 γ 는 D-CBG의 γ 와 같은 지위의 하이퍼파라미터이며, 샘플러가 겨냥하는 분포는 닫힌 형태로 정의된다: $p_\gamma \propto q^\gamma p_\theta^{1-\gamma}$ (명제 1).
- $\gamma = 0 \rightarrow p_\theta$, $\gamma = 1 \rightarrow q$ (현행), $\gamma \rightarrow \infty \rightarrow$ 판별자 best-of- n (명제 4).
- D-CBG와의 차이는 tilt의 꼬리 거동뿐이다: $\sigma(\ell)^\gamma$ (포화) 대 $e^{\gamma\ell}$ (비포화) — 순위는 동일하게 움직인다 (Remark 2).
- 유한 n 에서 실질적 상한은 ESS가 정하며(편향 $O(1/\text{ESS})$, 명제 3), 현재 측정치 기준 $\gamma \in \{2, 4\}$ 는 안전 범위로 추정된다 — 스왑 시 ESS를 함께 기록하면 상한을 실측으로 확정할 수 있다.
- Lemma 3 마스킹 · 제안 보정 · 블록 lookahead 구조 모두 γ -일반화에서 형태 그대로 유지된다.